

摘要:

本文面向上市公司 ESG 报告的智能解析与指标抽取任务，建立了由数据采集、PDF 结构化解析、候选证据定位、指标约束抽取和结果校验组成的分层处理框架。首先，从巨潮资讯网构建包含 200 份 ESG 相关 PDF 的原始候选报告库，并通过路径、哈希、文件类型和索引字段完成文件级一致性校验；随后，采用 MinerU 3.4.0 的 hybrid-engine 高精度模式将候选报告转化为文本块、表格块、图片块和层级化文档结构。当前解析基线累计覆盖 10528 页文档，200 份报告均生成 Markdown、content_list.json 和 content_list_v2.json，解析状态均为 ok。其中，content_list_v2.json 被作为后续自动切片与证据定位的主入口，Markdown 和图片资源用于人工核查和证据追溯。在此基础上，本文将 ESG 指标抽取形式化为“指标定义-候选证据-结构化输出”的约束映射过程，避免直接对整份长文档进行无约束生成。该框架为后续构建不少于 50 个 ESG 指标的抽取体系提供了可复现的数据基础和方法接口。

关键字： ESG 报告 PDF 解析 指标抽取 大语言模型 结构化数据

目录

1. 问题重述	3
1.1 问题背景	3
1.2 任务要求	3
2. 问题分析	3
2.1 问题特征分析	3
2.2 技术路线分析	4
3. 模型假设	4
4. 符号说明	5
5. 数据来源与预处理	5
5.1 原始报告采集	5
5.2 PDF 解析与结构化组织	5
6. 模型建立	6
6.1 系统总体框架	6
6.2 PDF 结构化解析模型	7
6.3 指标体系设计	8
6.4 结构化抽取模型	8
7. 模型求解与实验设计	8
7.1 解析结果生成	8
7.2 候选证据切片	8
7.3 实验样本确定	8
7.4 评价指标	9
8. 模型评价	9
8.1 模型优点	9
8.2 模型不足	9
9. 参考文献	9
附录 A 项目文件说明	10
附录 B 复现命令	10

1. 问题重述

1.1 问题背景

环境、社会与治理（Environmental, Social and Governance, ESG）信息披露已经成为评价企业可持续发展能力、社会责任履行情况和治理水平的重要依据。上市公司通常以年度 ESG 报告、可持续发展报告或社会责任报告的形式披露相关内容，报告中既包含温室气体排放、能源消耗、员工培训时长、女性高管占比等定量指标，也包含 ESG 战略目标、气候风险管理、员工权益保障、反腐败机制等定性描述。

ESG 报告多以 PDF 文件形式发布，文档篇幅较长，版式结构差异较大。不同公司对同一指标可能采用不同表述方式，同一报告中的重要信息也可能分散在正文段落、表格、图表说明和附注中。若完全依赖人工阅读和录入，在报告数量较多时效率较低，并且容易受到指标口径、单位写法和人工理解差异的影响。传统的关键词匹配或固定模板规则可以处理部分格式稳定的信息，但难以覆盖 ESG 报告中大量非结构化文本和复杂表格。

赛题要求结合大语言模型技术，设计并实现一套 ESG 报告数据智能提取与分析系统。系统需要在合法合规的前提下采集不少于 100 份 A 股或港股上市公司发布的 ESG 报告 PDF，完成文档格式统一、文本提取、表格识别等预处理；构建不少于 50 个 ESG 关键指标的抽取体系，并覆盖环境、社会、治理三个维度；在此基础上实现定量指标和定性指标的结构化抽取。

1.2 任务要求

根据赛题内容，本文需要解决的任务可以概括为三个方面。第一，构建可追溯的原始 PDF 报告来源。该任务要求采集足够规模的 ESG 相关报告，并建立本地文件与公告来源之间的索引关系，为后续解析和核查提供基础。第二，构建 ESG 指标体系。该任务要求在环境、社会、治理三个维度下组织不少于 50 个关键指标，同时区分定量指标和定性指标，并明确不同类型指标的抽取口径。第三，建立结构化抽取方法。该任务要求从 PDF 解析结果中定位与指标相关的文本或表格证据，并输出可用于后续分析的 JSON、CSV 等结构化结果。

需要指出的是，数据采集所得 PDF 是后续处理的原始候选报告集合。候选报告在文件层面通过校验后，本文已进一步完成批量 PDF 解析和结构化解析结果整理。后续模型实验或评测仍需在指标体系和人工核查方案确定后划分样本范围。

2. 问题分析

2.1 问题特征分析

本题不同于只需要建立单一数学模型并求解数值结果的传统优化题。ESG 报告智能抽取任务同时包含文档数据处理、指标体系设计和自然语言信息抽取三个环节。三个环节之间具有明显的依赖关系：若 PDF 解析质量不足，后续指标检索将缺少可靠文本；若指标体系定义不清，模型输出即使格式正确也难以用于评价；若结构化抽取缺少证据约束，则大语言模型可能输出缺乏原文依据的结果。

从输入数据看，ESG 报告具有长文档、多版式、多语言表达和多信息载体的特点。报告中的定量指标往往伴随单位、统计范围和时间口径，例如“温室气体排放总量”“综合能源消耗量”“员工培训总时长”等；定性指标则通常以段落形式出现，例如“气候风险管理措施”“员工权益保障政策”“反腐败机制说明”等。定量指标强调数值与单位的准确匹配，定性指标强调原文语义的完整保留，两者对抽取方法的要求并不相同。

从输出要求看，赛题并不只要求判断报告是否包含某个关键词，而是要求提取可验证、可复核、可进一步分析的结构化结果。因此，本文将后续系统设计为“PDF 解析-候选证据检索-指标约束抽取-结果校验”的流程。该流程将长文档处理问题分解为若干局

部任务，有利于降低一次性输入整份 PDF 带来的噪声。

2.2 技术路线分析

本文采用分层建模思路处理该问题。数据层负责建立原始候选 PDF 报告库，并保存公告来源、本地路径和文件哈希值等信息；解析层负责将 PDF 转换为文本块、表格块和版面结构；指标层负责给出 ESG 指标 schema，包括指标名称、所属维度、指标类型、单位要求和缺失值规则；抽取层负责根据指标定义检索相关证据，并调用大语言模型生成结构化结果；校验层负责检查输出字段、数值单位、原文证据和缺失标记是否符合规则。

该技术路线的核心是先约束输入，再约束输出。对于每个指标，系统不直接要求模型阅读整份报告，而是先利用指标名称、同义表达和章节线索检索候选证据片段，再将证据片段与指标定义一起输入模型。这样能够减少无关文本干扰，也便于人工复核模型结果。对于未检索到有效证据的指标，输出保持为空值，避免模型根据常识补写报告中不存在的内容。

3. 模型假设

为保证建模过程清晰，本文作出如下假设：

1. 假设 CNINFO 上公开披露的 PDF 报告可以作为本文原始候选报告库的数据来源，公告详情页和 PDF 链接能够用于结果追溯。
2. 假设文件级校验通过的 PDF 均可在本地读取；批量解析成功说明其可以转化为机器可读结构，但不代表每个指标都能在每份报告中找到原文证据。
3. 假设 ESG 指标可以按照环境、社会、治理三个维度进行组织，且每个指标可以进一步定义为定量指标或定性指标。
4. 假设同一指标在不同报告中可能存在不同名称、不同单位或不同统计口径，后续抽取时需要保留原文上下文作为证据。
5. 假设报告中未出现的指标应记为空值或缺失标记，不使用模型推断值替代原文证据。
6. 假设后续进入指标评测或人工标注的样本应基于当前解析基线继续筛选，而不是直接将全部原始候选 PDF 等同于训练集或测试集。

4. 符号说明

符号	含义
D	原始候选 PDF 报告库
d_i	第 i 份候选 PDF 报告
N	候选 PDF 数量, 当前 $N = 200$
C_i	第 i 份报告对应的公司简称
S_i	第 i 份报告对应的股票代码
P_i	第 i 份报告的本地保存路径
H_i	第 i 份报告的文件哈希值
B_i	第 i 份报告解析后的内容块集合
b_{ik}	第 i 份报告中的第 k 个解析内容块
I	ESG 指标集合
q_j	第 j 个 ESG 指标
E_{ij}	报告 d_i 中与指标 q_j 相关的候选证据片段
V_{ij}	报告 d_i 中指标 q_j 的抽取结果
U_{ij}	定量指标结果对应的单位

5. 数据来源与预处理

5.1 原始报告采集

本文的数据采集对象为上市公司公开披露的 ESG 相关 PDF 报告, 数据来源为巨潮资讯网 (CNINFO)。采集阶段以“ESG 报告”为主要检索关键词, 并结合可持续发展报告、社会责任报告、环境、社会及治理报告等题名特征进行筛选。对于每条公告记录, 系统保存股票代码、公司简称、公告标题、公告日期、公告详情页链接、PDF 下载链接、原始附件路径、原始 PDF 文件名、规范化文件名、本地保存路径和文件哈希值等信息。

当前已获得 200 份 PDF 文件。该集合只称为原始候选 PDF 报告库, 不能称为训练集、测试集、最终实验数据集或标注数据集。其作用是为后续 PDF 解析、指标体系构建、结构化抽取和人工核查提供原始材料。是否进入指标评测或人工标注环节, 需要依据解析质量、指标覆盖情况和任务匹配程度进一步确定。

在采集过程中, 本文剔除了公告摘要、英文版报告以及仅提示披露事项但不构成完整报告正文的公告文件。保留下来的 PDF 文件统一存放于 `data/raw_pdfs/` 目录, 主索引文件为 `data/report_index.csv`。主索引只包含成功下载且本地路径有效的 PDF 记录, 不混入 `skipped` 或 `failed` 记录。

由表 1 可知, 当前原始候选报告库在文件层面是完整的: PDF 文件数量与索引记录数一致, 全部 `local_path` 均指向真实存在的本地文件, 主索引中 `error` 字段非空数量为 0。需要注意的是, 索引中的 `year` 字段来自公告记录或公告标题, 可能对应公告发布年份, 不应直接解释为报告所属年份。

5.2 PDF 解析与结构化组织

文件级干净只说明 PDF 文件存在、路径正确、下载无错误, 并不能直接提供可用于指标抽取的文本块、表格块和图片证据。为统一后续处理入口, 本文使用 MinerU 3.4.0

表 1 原始候选 ESG 报告库文件级统计

统计项	数值
候选 PDF 数量	200
索引记录数	200
公司去重数量	198
股票代码去重数量	200
数据来源	CNINFO
ESG 报告	171
可持续发展报告	18
ESG 暨社会责任报告	11
下载错误记录	0
local_path 校验	200/200 通过

对 200 份候选 PDF 进行全量解析，将原始 PDF 转换为三类可复用产物：供人工阅读的 Markdown 文本、供程序处理的结构化 JSON，以及用于图表和版面证据追溯的图片资源。解析结果整理为 data/parsed_reports_v1/ 基线目录。该目录不保留 PDF 副本、版面调试 PDF 和中间态 JSON，使后续建模只依赖已确认的结构化结果。

解析基线的数据目录结构如下：

$$\text{data/parsed_reports_v1/reports/} \rightarrow \begin{cases} *.md, \\ *_content_list.json, \\ *_content_list_v2.json, \\ images/. \end{cases}$$

其中 content_list.json 为扁平内容块列表，保留文本、表格、图片、页码和边界框等字段；content_list_v2.json 将标题、段落、列表、表格、图片等内容组织为更接近文档逻辑的层级结果。对于后续指标抽取任务，层级结构比纯 Markdown 更适合切片和定位证据，因为它能够保留块类型、标题层级和资源路径。本文因此将 content_list_v2.json 设为自动处理主入口，将 Markdown 作为人工核查入口。

表 2 说明，当前解析基线已经覆盖全部候选 PDF，并为每份报告提供了机器处理所需的结构化入口。后续训练集、验证集或测试集的划分不在本节直接设定，应在 ESG 指标体系、抽取规则和人工核查标准确定后完成。

6. 模型建立

6.1 系统总体框架

本文建立的 ESG 报告智能抽取系统由五个模块组成。数据管理模块维护原始候选 PDF 报告库、索引表和文件校验信息；PDF 解析模块将 PDF 转换为文本块、表格块、图片块和标题层级；指标 schema 模块定义 ESG 指标名称、所属维度、指标类型、单位要求和缺失规则；候选证据模块根据指标定义在解析块中筛选相关片段；结构化抽取与校验模块根据候选证据生成统一格式的抽取结果，并检查数值、单位、证据和缺失标记是否符合约束。

表 2 结构化解析结果统计

统计项	数值
解析 PDF 数量	200
解析页数	10528
Markdown 文件数	200
content_list.json 文件数	200
content_list_v2.json 文件数	200
图片文件数	43175
Markdown 总字符数	17740555
图片引用数	30465
表格标记数	6713
解析状态为 ok 的报告数	200
协作目录大小	约 2.2 GB

对于报告 d_i 和指标 q_j ，抽取过程可表示为

$$V_{ij} = F(q_j, E_{ij}, R_j),$$

其中 E_{ij} 为从报告中检索得到的候选证据片段， R_j 为指标 q_j 对应的抽取规则， $F(\cdot)$ 表示由提示模板、大语言模型和输出校验共同组成的结构化抽取函数。若候选证据为空或输出结果不能通过校验，则 V_{ij} 记为空值。该表达强调抽取结果必须受到原文证据和指标规则共同约束，而不是由模型直接根据常识生成。

6.2 PDF 结构化解析模型

PDF 解析模块将原始报告 d_i 映射为内容块集合

$$B_i = \{b_{i1}, b_{i2}, \dots, b_{im_i}\},$$

其中 m_i 为第 i 份报告解析得到的内容块数量。每个内容块 b_{ik} 至少包含块类型、文本或资源路径、页面位置和版面边界信息。块类型包括标题、段落、列表、表格、图片、页眉和页码等。对于图片和表格块，解析结果同时保存图片路径、表格正文或表格标注；对于标题块，解析结果保存标题层级，便于后续按章节聚合。

本文将 PDF 解析视为从非结构化版面到半结构化内容块的映射过程。全量解析的参数集合记为

$$\Theta_{\text{parse}} = (\text{hybrid-engine}, \text{effort=high}, \text{mode=auto}, \\ \text{lang=ch}, \text{table=true}, \text{formula=true}, \\ \text{image-analysis=true}).$$

其中 `hybrid-engine` 指定混合解析后端，`effort=high` 对应高精度推理设置，`mode=auto` 表示解析器根据页面特征自动选择处理方式，`lang=ch` 指定中文文档环境，后三个布尔参数分别表示启用表格、公式和图片相关分析。全量解析完成后，从 MinerU 输出中提取 Markdown、两版 content list JSON 和图片目录，形成当前解析基线。完整复现命令放在附录中，正文只保留参数含义和模型接口。

6.3 指标体系设计

指标体系采用“维度-主题-指标”的层级结构。环境维度主要覆盖温室气体排放、能源消耗、水资源、污染物排放、废弃物处理和绿色运营等主题；社会维度主要覆盖员工权益、职业健康安全、员工培训、供应链管理、客户责任和社区公益等主题；治理维度主要覆盖董事会结构、内部控制、反腐败、风险管理、信息披露和股东权益等主题。

定量指标要求提取数值、单位和原文上下文。例如温室气体排放总量、能源消耗总量、员工培训总时长、女性高管占比等指标，需要保存数值本身、单位和统计口径。定性指标要求提取语义完整的原文段落。例如 ESG 战略目标、气候风险管理措施、员工权益保障政策、反腐败机制描述等指标，不宜只截取孤立关键词，而应保留能够表达完整含义的句群。

6.4 结构化抽取模型

结构化抽取模型分为候选证据检索和指标结果生成两个阶段。候选证据检索阶段根据指标名称、同义表达和报告章节信息，从 PDF 解析结果中筛选与指标相关的文本块或表格块。指标结果生成阶段将候选证据片段、指标定义和输出格式要求输入大语言模型，要求模型返回统一结构的 JSON 记录。

输出记录至少包含公司、股票代码、报告文件、指标名称、ESG 维度、指标类型、抽取值、单位、原文证据、页码或章节、错误说明等字段。对于定量指标，数值与单位分列保存；对于定性指标，抽取值保留原文表述。该设计的目的是使模型输出能够被人工复核，也能被后续统计分析直接读取。

7. 模型求解与实验设计

7.1 解析结果生成

当前阶段已经完成全部 200 份候选 PDF 的批量解析。解析任务共处理 10528 页文档，耗时 3607.91 秒，所有批次正常结束。本文未将完整 MinerU 过程目录作为最终数据入口，而是将每份报告整理为 .md、content_list.json、content_list_v2.json 和 images/ 四类产物。全量索引文件 data/parsed_reports_v1/manifest.csv 记录每份报告的页数、文件大小、Markdown 字符数、标题数、图片引用数、表格标记数和解析状态。

该处理方式使后续实验可以从统一的结构化入口读取数据。若任务需要人工核查某个抽取结果，可通过 Markdown 或图片路径回到原文附近；若任务需要程序化切片，则可直接读取 content_list_v2.json 中的标题、段落、表格和图片块。与直接读取整篇 Markdown 相比，按内容块读取可以减少跨章节拼接造成的噪声，也便于保留证据所在的页面和版面位置。

7.2 候选证据切片

对任意报告 d_i 和指标 q_j ，候选证据集合由解析内容块筛选得到：

$$E_{ij} = \{b_{ik} \in B_i \mid \phi(b_{ik}, q_j) = 1\},$$

其中 $\phi(\cdot)$ 表示证据筛选函数。该函数可以结合指标名称、同义表达、标题层级、页码位置和块类型进行判断。对于定量指标，筛选函数优先保留包含数值、单位和表格结构的内容块；对于定性指标，筛选函数优先保留标题邻近段落和语义完整的句群。这样可以减少长文档中无关段落对大语言模型抽取的干扰。

7.3 实验样本确定

实验样本不直接等同于原始候选报告库。当前 200 份报告已经完成统一解析，可以作为后续筛选和抽取的基础数据。若后续需要构建开发集、测试集或人工标注子集，应在当前解析基线内根据报告类型、行业覆盖、解析质量、指标覆盖率和人工核查成本进

一步划分。当前版本不设定具体比例，也不声称已经形成训练集或测试集。

7.4 评价指标

后续实验可从准确性和效率两个方面评价系统。对于定量指标，可采用数值匹配率、单位匹配率、字段级准确率和证据正确率；对于定性指标，可采用证据段落命中率、语义完整性评分和人工一致性评价。效率方面可记录单份报告解析时间、单份报告抽取时间和内存占用。上述指标需要在模型实验完成后计算，当前版本不填写具体数值。

8. 模型评价

8.1 模型优点

本文方案将数据采集、PDF 解析、指标体系和结构化抽取分层处理，能够减少不同环节错误相互混淆。原始候选 PDF 报告库保留了公告来源、PDF 下载链接、本地路径和文件哈希值，便于追溯；指标 `schema` 对定量指标和定性指标分别设定抽取要求，能够适应 ESG 报告中数值和文本并存的特点；候选证据检索减少了长文档输入噪声，也为人工核查提供了依据。

8.2 模型不足

当前方案仍依赖 PDF 解析质量。虽然 200 份报告均已成功生成结构化解析结果，但扫描件、复杂表格、跨页内容和图片化文字仍可能影响局部指标定位。大语言模型在处理相近指标时也可能混淆统计口径，因此需要通过候选证据约束、输出校验和人工抽样核查控制风险。当前版本尚未完成 ESG 指标 `schema` 定稿和结构化抽取实验，指标级效果需要在后续实验中进一步验证。

9. 参考文献

参考文献将在 PDF 解析工具、ESG 指标体系和大语言模型抽取方案进一步确定后补充。

附录 A 项目文件说明

当前项目的主要文件组织如下：

- 原始候选 PDF 报告保存于 data/raw_pdfs/;
- 主索引文件为 data/report_index.csv;
- 下载日志文件为 data/download_log.csv;
- 结构化解析结果保存于 data/parsed_reports_v1/;
- 全量解析索引文件为 data/parsed_reports_v1/manifest.csv;
- 项目处理链路、核心复现命令和当前数据口径记录在 docs/ 目录下的《台账》文件中。

附录 B 复现命令

PDF 解析的核心复现命令如下：

```
PATH=/home/sues01/.conda/envs/mineru/bin:$PATH \
NO_PROXY=127.0.0.1,localhost \
no_proxy=127.0.0.1,localhost \
/home/sues01/.conda/envs/mineru/bin/mineru \
-p data/raw_pdfs \
-o data/mineru_outputs/hybrid_high_all \
-b hybrid-engine \
--effort high \
-m auto \
-l ch \
-t true \
-f true \
--image-analysis true
```

解析完成后，从 MinerU 输出目录中提取每份报告的 Markdown、content_list.json、content_list_v2.json 和图片目录，并生成 data/parsed_reports_v1/manifest.csv 作为全量索引。