

摘 要:

摘要待补充。待 PDF 内容级解析、指标体系定稿、结构化抽取实验和人工核查完成后，摘要将按照“研究背景、方法框架、主要结果、模型特点与适用边界”的顺序统一撰写。

关键字： ESG 报告 PDF 解析 指标抽取 大语言模型 结构化数据

目录

1. 问题重述	3
1.1 问题背景	3
1.2 任务要求	3
2. 问题分析	3
2.1 问题特征分析	3
2.2 技术路线分析	4
3. 模型假设	4
4. 符号说明	5
5. 数据来源与预处理	5
5.1 原始报告采集	5
5.2 文件级干净与内容级可用	5
6. 模型建立	6
6.1 系统总体框架	6
6.2 指标体系设计	6
6.3 结构化抽取模型	7
7. 模型求解与实验设计	7
7.1 解析质量抽检	7
7.2 实验样本确定	7
7.3 评价指标	7
8. 模型评价	7
8.1 模型优点	7
8.2 模型不足	7
9. 参考文献	8
附录 A 项目文件说明	9

1. 问题重述

1.1 问题背景

环境、社会与治理（Environmental, Social and Governance, ESG）信息披露已经成为评价企业可持续发展能力、社会责任履行情况和治理水平的重要依据。上市公司通常以年度 ESG 报告、可持续发展报告或社会责任报告的形式披露相关内容，报告中既包含温室气体排放、能源消耗、员工培训时长、女性高管占比等定量指标，也包含 ESG 战略目标、气候风险管理、员工权益保障、反腐败机制等定性描述。

ESG 报告多以 PDF 文件形式发布，文档篇幅较长，版式结构差异较大。不同公司对同一指标可能采用不同表述方式，同一报告中的重要信息也可能分散在正文段落、表格、图表说明和附注中。若完全依赖人工阅读和录入，在报告数量较多时效率较低，并且容易受到指标口径、单位写法和人工理解差异的影响。传统的关键词匹配或固定模板规则可以处理部分格式稳定的信息，但难以覆盖 ESG 报告中大量非结构化文本和复杂表格。

赛题要求结合大语言模型技术，设计并实现一套 ESG 报告数据智能提取与分析系统。系统需要在合法合规的前提下采集不少于 100 份 A 股或港股上市公司发布的 ESG 报告 PDF，完成文档格式统一、文本提取、表格识别等预处理；构建不少于 50 个 ESG 关键指标的抽取体系，并覆盖环境、社会、治理三个维度；在此基础上实现定量指标和定性指标的结构化抽取。

1.2 任务要求

根据赛题内容，本文需要解决的任务可以概括为三个方面。第一，构建可追溯的原始 PDF 报告来源。该任务要求采集足够规模的 ESG 相关报告，并建立本地文件与公告来源之间的索引关系，为后续解析和核查提供基础。第二，构建 ESG 指标体系。该任务要求在环境、社会、治理三个维度下组织不少于 50 个关键指标，同时区分定量指标和定性指标，并明确不同类型指标的抽取口径。第三，建立结构化抽取方法。该任务要求从 PDF 解析结果中定位与指标相关的文本或表格证据，并输出可用于后续分析的 JSON、CSV 等结构化结果。

需要指出的是，数据采集所得 PDF 只是后续处理的原始候选报告集合。候选报告在文件层面通过校验后，仍需经过内容级解析质量检查、重复文件排查、任务相关性判断和人工抽样核查，才能进一步确定哪些样本进入模型实验或评测环节。

2. 问题分析

2.1 问题特征分析

本题不同于只需要建立单一数学模型并求解数值结果的传统优化题。ESG 报告智能抽取任务同时包含文档数据处理、指标体系设计和自然语言信息抽取三个环节。三个环节之间具有明显的依赖关系：若 PDF 解析质量不足，后续指标检索将缺少可靠文本；若指标体系定义不清，模型输出即使格式正确也难以用于评价；若结构化抽取缺少证据约束，则大语言模型可能输出缺乏原文依据的结果。

从输入数据看，ESG 报告具有长文档、多版式、多语言表达和多信息载体的特点。报告中的定量指标往往伴随单位、统计范围和时间口径，例如“温室气体排放总量”“综合能源消耗量”“员工培训总时长”等；定性指标则通常以段落形式出现，例如“气候风险管理措施”“员工权益保障政策”“反腐败机制说明”等。定量指标强调数值与单位的准确匹配，定性指标强调原文语义的完整保留，两者对抽取方法的要求并不相同。

从输出要求看，赛题并不只要求判断报告是否包含某个关键词，而是要求提取可验证、可复核、可进一步分析的结构化结果。因此，本文将后续系统设计为“PDF 解析-候选证据检索-指标约束抽取-结果校验”的流程。该流程将长文档处理问题分解为若干局

部任务，有利于降低一次性输入整份 PDF 带来的噪声。

2.2 技术路线分析

本文拟采用分层建模思路处理该问题。数据层负责建立原始候选 PDF 报告库，并保存公告来源、本地路径和文件哈希值等信息；解析层负责将 PDF 转换为文本块、表格块和版面结构；指标层负责给出 ESG 指标 schema，包括指标名称、所属维度、指标类型、单位要求和缺失值规则；抽取层负责根据指标定义检索相关证据，并调用大语言模型生成结构化结果；校验层负责检查输出字段、数值单位、原文证据和缺失标记是否符合规则。

该技术路线的核心是先约束输入，再约束输出。对于每个指标，系统不直接要求模型阅读整份报告，而是先利用指标名称、同义表达和章节线索检索候选证据片段，再将证据片段与指标定义一起输入模型。这样能够减少无关文本干扰，也便于人工复核模型结果。对于未检索到有效证据的指标，输出保持为空值，避免模型根据常识补写报告中不存在的内容。

3. 模型假设

为保证建模过程清晰，本文作出如下假设：

1. 假设 CNINFO 上公开披露的 PDF 报告可以作为本文原始候选报告库的数据来源，公告详情页和 PDF 链接能够用于结果追溯。
2. 假设文件级校验通过的 PDF 均可在本地读取，但文件可读取不代表报告内容一定满足后续指标抽取要求。
3. 假设 ESG 指标可以按照环境、社会、治理三个维度进行组织，且每个指标可以进一步定义为定量指标或定性指标。
4. 假设同一指标在不同报告中可能存在不同名称、不同单位或不同统计口径，后续抽取时需要保留原文上下文作为证据。
5. 假设报告中未出现的指标应记为空值或缺失标记，不使用模型推断值替代原文证据。
6. 假设后续进入实验的样本应来自内容级筛选后的有效样本，而不是无条件使用全部原始候选 PDF。

4. 符号说明

符号	含义
D	原始候选 PDF 报告库
d_i	第 i 份候选 PDF 报告
N	候选 PDF 数量, 当前 $N = 200$
C_i	第 i 份报告对应的公司简称
S_i	第 i 份报告对应的股票代码
P_i	第 i 份报告的本地保存路径
H_i	第 i 份报告的文件哈希值
I	ESG 指标集合
q_j	第 j 个 ESG 指标
E_{ij}	报告 d_i 中与指标 q_j 相关的候选证据片段
V_{ij}	报告 d_i 中指标 q_j 的抽取结果
U_{ij}	定量指标结果对应的单位

5. 数据来源与预处理

5.1 原始报告采集

本文的数据采集对象为上市公司公开披露的 ESG 相关 PDF 报告，数据来源为巨潮资讯网（CNINFO）。采集阶段以“ESG 报告”为主要检索关键词，并结合可持续发展报告、社会责任报告、环境、社会及治理报告等题名特征进行筛选。对于每条公告记录，系统保存股票代码、公司简称、公告标题、公告日期、公告详情页链接、PDF 下载链接、原始附件路径、原始 PDF 文件名、规范化文件名、本地保存路径和文件哈希值等信息。

当前已获得 200 份 PDF 文件。该集合只称为原始候选 PDF 报告库，不能称为训练集、测试集、最终实验数据集或标注数据集。其作用是为后续 PDF 解析、指标体系构建、结构化抽取和人工核查提供原始材料。是否进入后续实验，需要依据内容级解析质量和任务匹配程度进一步确定。

在采集过程中，本文剔除了公告摘要、英文版报告以及仅提示披露事项但不构成完整报告正文的公告文件。保留下来的 PDF 文件统一存放于 `data/raw_pdfs/` 目录，主索引文件为 `data/report_index.csv`。主索引只包含成功下载且本地路径有效的 PDF 记录，不混入 `skipped` 或 `failed` 记录。

由表 1 可知，当前原始候选报告库在文件层面是完整的：PDF 文件数量与索引记录数一致，全部 `local_path` 均指向真实存在的本地文件，主索引中 `error` 字段非空数量为 0。需要注意的是，索引中的 `year` 字段来自公告记录或公告标题，可能对应公告发布年份，不应直接解释为报告所属年份。

5.2 文件级干净与内容级可用

文件级干净只说明 PDF 文件存在、路径正确、下载无错误，并不能保证每份报告都适合进入后续实验。实际处理时仍可能遇到扫描质量差、表格跨页、正文与标题相关性不足、重复或近重复披露、章节结构难以解析等问题。因此，本文将文件级校验之后的质量控制分为两步：首先抽样检查 PDF 解析质量，其次根据解析结果和任务相关性筛选有效样本。

表 1 原始候选 ESG 报告库文件级统计

统计项	数值
候选 PDF 数量	200
索引记录数	200
公司去重数量	198
股票代码去重数量	200
数据来源	CNINFO
ESG 报告	171
可持续发展报告	18
ESG 暨社会责任报告	11
下载错误记录	0
local_path 校验	200/200 通过

后续内容级清洗将重点处理以下情况：去除重复或近重复文件；剔除无法打开、解析失败或内容不完整的 PDF；剔除标题相关但正文不满足 ESG 信息抽取任务的文件；检查 MinerU 或其他解析工具的文本、表格和版面解析质量；根据解析质量和任务需求确定实验样本。训练集、验证集和测试集的最终划分将在有效样本确认后进行，当前阶段不设定具体比例。

6. 模型建立

6.1 系统总体框架

本文拟建立的 ESG 报告智能抽取系统由四个模块组成。第一是数据管理模块，用于维护原始候选 PDF 报告库、索引表和文件校验信息；第二是 PDF 解析模块，用于将 PDF 转换为文本块、表格块和版面结构；第三是指标 schema 模块，用于定义 ESG 指标名称、所属维度、指标类型、单位要求和抽取规则；第四是结构化抽取模块，用于根据候选证据片段生成统一格式的抽取结果。

对于报告 d_i 和指标 q_j ，抽取过程可表示为

$$V_{ij} = F(q_j, E_{ij}, R_j),$$

其中 E_{ij} 为从报告中检索得到的候选证据片段， R_j 为指标 q_j 对应的抽取规则， $F(\cdot)$ 表示由提示模板、大语言模型和输出校验共同组成的结构化抽取函数。若候选证据为空或输出结果不能通过校验，则 V_{ij} 记为空值。

6.2 指标体系设计

指标体系采用“维度-主题-指标”的层级结构。环境维度主要覆盖温室气体排放、能源消耗、水资源、污染物排放、废弃物处理和绿色运营等主题；社会维度主要覆盖员工权益、职业健康安全、员工培训、供应链管理、客户责任和社区公益等主题；治理维度主要覆盖董事会结构、内部控制、反腐败、风险管理、信息披露和股东权益等主题。

定量指标要求提取数值、单位和原文上下文。例如温室气体排放总量、能源消耗总量、员工培训总时长、女性高管占比等指标，需要保存数值本身、单位和统计口径。定性指标要求提取语义完整的原文段落。例如 ESG 战略目标、气候风险管理措施、员工

权益保障政策、反腐败机制描述等指标，不宜只截取孤立关键词，而应保留能够表达完整含义的句群。

6.3 结构化抽取模型

结构化抽取模型分为候选证据检索和指标结果生成两个阶段。候选证据检索阶段根据指标名称、同义表达和报告章节信息，从 PDF 解析结果中筛选与指标相关的文本块或表格块。指标结果生成阶段将候选证据片段、指标定义和输出格式要求输入大语言模型，要求模型返回统一结构的 JSON 记录。

输出记录至少包含公司、股票代码、报告文件、指标名称、ESG 维度、指标类型、抽取值、单位、原文证据、页码或章节、错误说明等字段。对于定量指标，数值与单位分列保存；对于定性指标，抽取值保留原文表述。该设计的目的是使模型输出能够被人工复核，也能被后续统计分析直接读取。

7. 模型求解与实验设计

7.1 解析质量抽检

在批量解析全部候选报告之前，本文拟先从 200 份原始候选 PDF 报告库中抽样 20 份，进行内容级解析质量检查。检查内容包括 PDF 是否可打开、正文文本顺序是否稳定、表格是否被正确识别、跨页表格是否断裂、章节标题和页码是否能保留等。抽检结果将记录为 `parse_quality_sample_20.csv`，并作为后续筛选有效样本的依据。

7.2 实验样本确定

实验样本不直接等同于原始候选报告库。只有通过内容级解析质量检查、任务相关性检查和必要人工核查的 PDF，才适合进入后续结构化抽取实验。若后续需要构建开发集、测试集或人工标注子集，应在有效样本范围内进一步划分。当前阶段尚未完成上述筛选，因此本文不写具体划分比例。

7.3 评价指标

后续实验可从准确性和效率两个方面评价系统。对于定量指标，可采用数值匹配率、单位匹配率、字段级准确率和证据正确率；对于定性指标，可采用证据段落命中率、语义完整性评分和人工一致性评价。效率方面可记录单份报告解析时间、单份报告抽取时间和内存占用。上述指标需要在模型实验完成后计算，当前版本不填写具体数值。

8. 模型评价

8.1 模型优点

本文方案将数据采集、PDF 解析、指标体系和结构化抽取分层处理，能够减少不同环节错误相互混淆。原始候选 PDF 报告库保留了公告来源、PDF 下载链接、本地路径和文件哈希值，便于追溯；指标 `schema` 对定量指标和定性指标分别设定抽取要求，能够适应 ESG 报告中数值和文本并存的特点；候选证据检索减少了长文档输入噪声，也为人工核查提供了依据。

8.2 模型不足

当前方案仍依赖 PDF 解析质量。若报告为扫描件、表格结构复杂或跨页严重，解析结果可能影响后续指标定位。大语言模型在处理相近指标时也可能混淆统计口径，因此需要通过输出校验和人工抽样核查控制风险。当前版本尚未完成内容级解析质量评估和结构化抽取实验，模型效果需要在后续实验中进一步验证。

9. 参考文献

参考文献将在 PDF 解析工具、ESG 指标体系和大语言模型抽取方案进一步确定后补充。

附录 A 项目文件说明

当前项目的主要文件组织如下：

- 原始候选 PDF 报告保存于 data/raw_pdfs/;
- 主索引文件为 data/report_index.csv;
- 下载日志文件为 data/download_log.csv;
- 项目状态说明、数据说明和任务计划分别记录在 docs/PROJECT_STATUS.md、docs/DATA_CARD.md 和 docs/TASK_PLAN.md 中。