

第八届中国研究生人工智能创新大赛

ESG ClaimGuard

可持续披露一致性预审系统

项目文档

版本 v1.0

日期：2026 年 8 月 31 日

团队名称：队不起队不起

参赛组别：开放赛题-生成式大语言模型与智能体

目录

1 项目概况	3
1.1 背景和基础	3
1.2 场景和价值	4
1.3 所需支持	4
2 项目规划	4
2.1 整体目标	4
2.2 技术创新点	5
3 实施方案	5
3.1 技术可行性分析	5
3.2 技术细节	6
3.2.1 问题形式化	6
3.2.2 文档解析与候选召回	6
3.2.3 受约束抽取与证据门	6
3.2.4 定量来源与问题生成	6
3.2.5 人工处置与工程验证	7
3.3 计划和分工	7
4 运行结果与模型评价	7
4.1 正式运行结果	7
4.2 结果分析	9
4.3 模型评价与适用边界	11
4.4 结论	11
5 参考资料	11

记录更改历史

序号	更改原因	版本	作者	更改日期	备注
1	正式提交版定稿	v1.0	队不起队不起	2026 年 8 月 31 日	数据、模型、系统和交付口径统一至冻结正式版本

本系统用于定位和整理 ESG 报告中的披露证据。输出结果是供人员复核的候选记录，不是企业 ESG 评分、违规认定或法定鉴证意见。本文报告已经完成的工程结果，不使用未经独立人工评测的数据宣称 Precision、Recall 或 F1。

1 项目概况

1.1 背景和基础

一名 ESG 报告复核人员通常需要回答四个连续问题：某项指标是否在报告中出现，原文位于哪一页，数值的主体、期间、范围和单位是否一致，以及该数值能否从原文直接读取或复算。真正耗时的并不是阅读某一句话，而是在数十至数百页的正文、表格、脚注和附录之间找到相关内容，再把判断依据整理成可留痕的工作记录。

现有工具只能解决其中一部分。关键词检索容易复现，但同一指标可能存在多种写法，跨页表格和图文混排也会破坏文本顺序；把整份 PDF 交给大模型能够得到较流畅的回答，却很难保证页码、引文和数值来源稳定；普通 RAG 可以返回相关片段 [3-4]，但“检索到相关内容”仍不等于“形成可复核证据”。因此，本项目要解决的不是让模型多回答一个问题，而是让每个回答都能够回到报告原文，并能进入后续人工处置。

ESG ClaimGuard 将该任务定义为受证据约束的信息抽取问题。输入是报告 PDF 和 ESG-65 指标池，输出是按“报告 × 指标”组织的披露状态、页码、区块、逐字引文、数值及单位来源。模型负责理解语义，程序负责检查证据，复核人员负责最终处置。三者的职责被明确分开，避免把大模型生成的自然语言直接当作结论。

项目已有工作基础包括 200 份冻结报告、10,528 页规范化解析结果、65 项 ESG 指标、13,000 个唯一任务及一套可运行的网页工作台。正式运行得到 found 7,688 条、missing 5,312 条、error 0。这里的 found 表示找到了满足内部证据合同的候选，missing 表示在当前解析与召回范围内没有找到合格证据；两者都不是对企业披露质量的评分。

ESG ClaimGuard 正式链路



MinerU 与 Qwen 顺序驻留；任何 found 必须回到同报告、同页、同 block 的 canonical 原文

系统端到端流水线

图 1 给出了全文的技术主线。报告先被拆成带页码和版面信息的规范区块，指标召回模块再从中筛选候选，大模型只对候选内容作结构化判断。模型输出随后经过页码、区块、逐字引文、数值和单位检查，不满足条件的记录不会以 found 进入正式结果。通过验证的候选进入工作台，由复核人员查看原文并记录处置意见。后续章节依次说明这五个环节为什么需要、如何实现以及用什么证据验收。

1.2 场景和价值

系统面向报告编制人员、企业合规人员和内部审阅团队。典型使用方式是：选择一份报告，按指标查看系统找到的披露候选，打开对应页码和原文，确认数值与口径，最后记录确认、修正、待补材料、接受风险或排除等处置。系统总览用于观察任务规模 and 状态分布，证据页用于逐条核对，问题页保存处理过程，导出功能生成可继续编辑的预审底稿。

这一场景的价值在于减少“定位、复制、整理”这类机械工作，而不是替代专业判断。若系统给出 missing，复核人员仍需考虑扫描质量、同义表达、报告适用范围等因素；若系统给出 found，也需要判断证据是否真正回答了指标要求。系统把搜索范围缩小并保留证据位置，使人员能够把时间用于口径判断和问题处置。

方案	能解决的问题	主要不足	是否适合直接形成复核记录
关键词或正则检索	精确查找已知词语	同义表达、表格和上下文处理较弱	需要人工重新整理
整份 PDF 自由问答	快速概括报告内容	页码、引文和缺失判断不稳定	不适合直接使用
普通切块 RAG	从相关片段生成回答	通常不强制数值来源和逐字证据	取决于额外校验
ESG ClaimGuard	按指标生成带页码、区块和引文的候选	仍受解析质量和指标口径约束	可直接进入人工复核流程

1.3 所需支持

正式版本采用单机顺序运行。MinerU 完成文档版面解析后释放相关资源，Qwen3.6 再进入抽取阶段，两类模型不同时占用显存。此次正式运行使用 NVIDIA GeForce RTX 5090 32,607 MiB 显存、AMD Ryzen Threadripper PRO 9955WX 处理器和 124.8 GiB 内存；网页端为 React/Vite，服务端为 Python。

在其他环境部署时，需要准备有权处理的报告文件、可运行文档解析和语言模型的 GPU，以及由使用方确认的指标口径。若将系统用于监管报送或鉴证业务，还需由法律、审计和行业人员确定适用标准与责任边界。上述条件影响部署范围，但不改变本次作品的计算方法。

2 项目规划

2.1 整体目标

参赛期间的目标被拆成五个可验收问题，而不是笼统地追求“智能化”：长篇 PDF 能否被转换为带页码的规范区块；65 项指标能否在 200 份报告上形成无遗漏、无重复的任务网格；每条 found 能否回到原文；定量结果能否说明数值和单位来源；复核人员能否在网页中查看证据、处理问题并导出记录。

待解决问题	设计目标	验收依据
复杂 PDF 难以统一读取	保留页码、区块类型、文本和版面位置	200 份报告解析清单与 10,528 页统计
指标任务容易漏跑或重复	建立报告与 ESG-65 指标的笛卡尔积	13,000 个唯一键, error 0
大模型回答难以追溯	found 必须绑定区块、页码和逐字引文	7,688 条 found 的证据合同结果
定量值来源不清	区分原文读取、公式推导和单位处理	3,214 条定量结果的来源字段
输出无法进入业务处置	提供证据查看、问题状态和底稿导出	工作台功能、API smoke 与测试记录

2.2 技术创新点

第一项改动针对长文档上下文过大。系统不把整份报告一次性交给语言模型，而是先按版面解析，再依据指标别名和语义相关性召回候选区块。该设计减少无关上下文，也使模型看到的内容可以被明确定位。

第二项改动针对生成结果难以审计。系统把“有答案”改写为一组必须同时成立的条件：报告存在、页码可解析、区块可定位、引文是区块原文的连续子串，定量结果还要记录数值和单位来源。提示词负责规定输出格式，程序校验负责决定结果能否进入正式数据。

第三项改动针对数值的可复算性。直接从原文读取的值、由明确表达式推导的值、沿用原文的单位以及经过归一或推断的单位分别记录。复核人员因此能够区分“报告原文写了什么”和“系统做了什么处理”。

第四项改动针对模型结果与实际工作脱节。抽取记录被转换为可处置的问题，人员可以查看证据、修正候选、标记待补材料、接受风险或排除，并将处理记录导出。系统优化的是复核过程，而不是单独展示一个模型分数。

3 实施方案

3.1 技术可行性分析

数据来自公开披露的 ESG、可持续发展和社会责任类报告。`input_manifest.csv` 固定了正式队列中的报告路径、SHA-256、页数和入选顺序，目录中的其他 PDF 不参与统计。指标池包含环境 25 项、社会 20 项和治理 20 项，既提供规范名称，也保存召回所需的别名和提示信息。

文档解析采用 MinerU2.5-Pro-2605-1.2B [1]，结构化抽取采用 Qwen3.6-27B Q4_K_M [2]。两者顺序运行，避免显存竞争。解析、召回、抽取和校验均保存中间产物；程序中断后可依据任务状态继续执行，不需要从第一份报告重新开始。冻结结果附带 manifest、validation、COMPLETE 标记和 SHA-256 校验和，便于在另一环境核对文件是否一致。

主要风险不是算力不足，而是输入和口径的不确定性。扫描件可能出现 OCR 错字，跨页表格可能

丢失表头，指标可能存在同义表达，数值还可能省略单位或范围。系统分别采用页级区块、候选扩展、精确引文检查、数值来源标记和人工回原文复核应对这些问题。无法由现有证据消除的不确定性保留给人员判断。

3.2 技术细节

3.2.1 问题形式化

设冻结报告集合为 R ，指标集合为 I ，任务集合为 $T = R \times I$ 。本次运行中 $|R| = 200$ 、 $|I| = 65$ ，因此 $|T| = 13,000$ 。对任务 $t = (r, i)$ ，系统输出状态 z 以及证据对象 $e = (\text{page}, \text{block_id}, \text{quote})$ ；若结果包含定量值，还输出 v 、 u 及其来源 origin 。

模型建立基于三个假设。其一，正式报告可以被转换为带稳定页码的规范区块；其二，支持一条抽取结果的原文能够在一个区块或少量相邻区块中找到；其三，自动结果只作为候选，最终业务判断由人员完成。当报告严重扫描损坏、证据跨越大量页面或指标口径依赖外部事实时，这些假设可能不成立，系统应返回 `missing` 或交由人工复核。

3.2.2 文档解析与候选召回

MinerU 将每页内容转换为文本、表格、标题、图片说明等规范区块，并保存页码、区块类型和位置。召回阶段以指标名称、别名和语义相关性筛选区块，不直接生成结论。这样做有两个作用：减少大模型上下文中的无关内容，并把后续输出限制在可定位的候选集合中。

召回没有把“没找到候选”解释为企业未披露。它只说明在当前解析和检索条件下没有出现满足阈值的内容。该区分贯穿数据结构、网页提示和最终结论。

3.2.3 受约束抽取与证据门

Qwen3.6 读取单个指标及其候选区块，返回固定 JSON，而不是自由文本。输出包括状态、原文引文、页码、区块、数值、单位和必要说明。程序随后执行确定性校验，其核心关系可写为：

```
evidence_valid = block_exists
                  AND page_matches_block
                  AND quote_is_exact_substring_of_block

final_found = model_returns_found
              AND evidence_valid
              AND required_fields_complete
```

证据门不判断一句话在业务上是否正确，它只检查模型声称引用的内容是否确实存在于指定原文。这个约束虽然简单，却切断了“答案看起来合理但无法定位”的路径。任何必填字段失败都会触发重试、保守降级或人工复核。

3.2.4 定量来源与问题生成

定量结果分为直接读取和明确推导两类。直接读取值保留原文数值及单位；推导值同时保存表达式和输入。单位若经过换算、归一或推断，也与原文单位分开记录。该设计使复核人员能够复算结果，

而不必猜测模型是否自行换算。

在业务层，声明可表示为 (subject, metric, period, value, unit, scope, evidence)。系统比较同一指标下的数值、单位和证据关系，生成待复核问题；条款映射只在市场归属可以确认时启用，且“未找到说明”不自动写成违规。当前正式结果对主体、期间和范围的结构化仍有限，因此跨声明规则被定位为辅助检查，不作为自动定责依据。

3.2.5 人工处置与工程验证

工作台从正式数据集读取报告、指标和证据。复核人员可以回到原文，修改候选内容，记录处理动作并导出底稿。每次处理保留问题状态和更新时间，使模型输出与人员结论可以区分。

工程验证包括任务唯一性、状态枚举、证据合同、定量来源、manifest 一致性、SHA-256、Python 测试、生产 API smoke 和前端构建。209 条被重试熔断器保留的记录经工程复核与纠错后写入正式结果；这部分用于修复运行异常，不作为准确率样本。

3.3 计划和分工

项目按需求与指标定义、数据与模型开发、系统集成、正式运行、材料整理五个阶段推进。需求阶段明确用户任务和证据边界；开发阶段完成报告解析、候选召回与受约束抽取；集成阶段完成网页工作台和处置流程；正式运行阶段冻结 200 份报告并生成 13,000 条结果；交付阶段完成测试、文档、视频和归档校验。上述阶段均已执行完毕。

- **队长：杨哲**——负责项目总体统筹、需求分析与方案设计，组织 ESG 指标口径和业务流程设计，协调系统开发、成果整合、参赛文档与演示材料制作。
- **队员 1：邱宇强**——负责 ESG 报告数据整理、MinerU 文档解析、候选召回与大模型抽取流程，实现证据定位、字段结构化和正式数据运行。
- **队员 2：王恒岳**——负责前后端工作台、证据复核与问题处置功能，实现数据可视化、接口联调、工程测试、运行验证和交付包整理。

4 运行结果与模型评价

4.1 正式运行结果

正式队列包含 200 份报告、10,528 页和 65 项指标。报告与指标形成 13,000 个唯一任务，最终 found 7,688 条、missing 5,312 条、error 0。运行级生成调用为 10,015 次，总墙钟时间 27,928.801 秒。最终结果中有 11,280 行保存了正 elapsed_seconds，这些行的耗时中位数为 2.765 秒，P95 为 3.683 秒；结果行数与生成调用数属于不同统计层级，不能混用。

验收对象	正式结果	可以支持的结论
任务网格	13,000/13,000, 重复键 0, error 0	正式队列全部处理完成
found 证据合同	7,688/7,688	页码、区块和逐字引文在内部数据中可追溯
定量来源字段	3,214/3,214	数值、单位及来源字段完整
生成调用	10,015 次, 调用错误 0	本次单卡顺序运行完成
软件验证	测试、API smoke、前端构建通过	提交版功能可以运行和复验




图 2 将任务规模和状态放在同一张图中。200 份报告与 65 项指标的乘积恰好为 13,000，说明结果不是抽样展示，而是覆盖冻结队列的完整网格。found 和 missing 只描述系统是否找到满足合同的候选，不能据此比较企业表现。error 为 0 说明任务都获得最终状态，但不代表每个状态都经过独立人工语义判定。




图 3 分开显示运行级调用数与结果行耗时。10,015 表示实际生成调用，11,280 表示保存了正耗时的结果行；一批调用可以影响多条结果，因此两个数不应相等。中位数 2.765 秒和 P95 3.683 秒说明大部分行的处理耗时较集中，但总墙钟还包含解析、召回、重试、写盘和任务调度，不能用行级中位数直接推算全程时间。

4.2 结果分析




图 4 显示环境、社会 and 治理维度的 found/missing 数分别为 2,363/2,637、2,550/1,450 和 2,775/1,225。治理维度的 found 比例较高，环境维度较低，但这一差异同时受到企业披露习惯、指标定义、版面质量和召回策略影响。现有数据无法把差异归因于企业表现或模型能力，因此该图主要用于估计各维度的复核工作量。




图 5 按报告汇总 found 数，最小值为 0，中位数为 42，最大值为 57。分布两端都值得人工关注：found 很少的报告可能存在扫描质量差、报告类型不匹配或披露确实较少等情况；found 很多也可能是同一段宽泛表述被多个指标重复引用。报告级分布因此被用作复核排序线索，而不是质量排名。




图 6 检查输出能否回到原文。7,688 条 found 均通过页码、区块和精确子串合同，失败数为 0。3,214 条定量结果中，value origin 包含直接读取 3,089 条、明确推导 125 条；unit origin 包含原文单位 3,105 条、归一或推断 109 条。该结果证明来源字段在正式数据中齐全，但不能证明模型对披露语义的判断全部正确。

4.3 模型评价与适用边界

该方案的优点来自职责分离。MinerU 解决版面读取，召回模块控制上下文，大模型处理同义表达，证据门检查原文存在性，人员承担最终判断。任一环节出现问题时，可以沿页码、区块、提示输入和处理记录定位原因。冻结 manifest 和校验和又保证了评审看到的数据与正式运行一致。

局限也很明确。OCR 错误会使正确证据无法通过精确子串检查；跨页表格和隐含单位可能需要人工拼接；主体、期间和范围尚未在所有记录中完整结构化，因此复杂的跨声明一致性检查只能作为候选提示；缺少独立人工测试集意味着本文不能回答语义准确率是多少。系统适合用于报告发布前的证据定位和内部预审，不适合直接输出企业评分、违规结论、投资建议或法定鉴证意见。

4.4 结论

本项目把 ESG 报告复核中最耗时的“找证据、抄原文、记位置”转换为一组按指标组织的证据任务。对每一条 found，系统保存报告、页码、区块和逐字引文；遇到定量结果时，再说明数值和单位来自原文、换算还是推导。复核人员可以在网页中查看这些信息，作出修正或处置，并导出工作记录。

200 份报告上的正式运行完成了 13,000 个任务，全部得到最终状态，error 为 0。证据合同、定量来源、软件测试和文件校验均通过。这些结果说明从 PDF 输入到复核底稿输出的工程流程已经能够运行，也说明模型输出能够在当前数据结构中回到原文。它们不证明系统比其他方法更准确，也不替代人员对披露含义和适用规则的判断。

ESG ClaimGuard 的实际作用，是先把可能相关的披露和依据整理到复核人员面前。这样，人员不必从头翻阅整份报告，可以把时间用于判断证据是否充分、数值口径是否一致以及问题应当如何处理。

5 参考资料

1. Wang B. et al. MinerU: An Open-Source Solution for Precise Document Content Extraction. arXiv:2409.18839, 2024. DOI: 10.48550/arXiv.2409.18839.
2. Qwen Team. Qwen3.6-27B Model Card. Hugging Face model repository, 2026. <https://huggingface.co/Qwen/Qwen3.6-27B>.
3. Gao Y. et al. Retrieval-Augmented Generation for Large Language Models: A Survey. arXiv:2312.10997, 2023.
4. Fan W. et al. A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models. KDD 2024. DOI: 10.1145/3637528.3671470.
5. 项目数据来源、软件版本、许可证和原创边界详见随附《来源与借鉴台账》《第三方依赖与许可》及冻结数据的 provenance 目录。