

第八届中国研究生人工智能创新大赛

ESG ClaimGuard

可持续披露一致性预审系统

项目文档

版本 v1.0

日期：2026 年 8 月 31 日

团队名称：队不起队不起

参赛组别：开放赛题-生成式大语言模型与智能体

目录

1 项目概况	3
1.1 背景和基础	3
1.2 场景和价值	4
1.3 所需支持	5
2 项目规划	5
2.1 整体目标	5
2.2 技术创新点	5
3 实施方案	6
3.1 技术可行性分析	6
3.2 技术细节	6
3.2.1 数据获取、筛选与冻结	6
3.2.2 问题形式化	7
3.2.3 版面解析与候选召回	7
3.2.4 受约束抽取与证据门	7
3.2.5 声明约束与问题生成	8
3.2.6 产品工作流与工程验证	8
3.3 计划和分工	9
4 运行结果与模型评价	9
4.1 正式运行结果	9
4.2 典型案例	10
4.3 结果分析	12
4.4 模型评价与适用边界	13
4.5 结论	13
5 参考资料	14

记录更改历史

序号	更改原因	版本	作者	更改日期	备注
1	正式提交版定稿	v1.0	队不起队不起	2026 年 8 月 31 日	数据、模型、系统和交付口径统一至冻结正式版本

本系统用于定位和整理 ESG 报告中的披露证据，输出是供人员复核的候选记录，不是企业 ESG 评分、违规认定、投资建议或法定鉴证意见。本文只报告可由仓库文件复验的工程结果，不使用未经独立人工评测的数据宣称准确率。

1 项目概况

1.1 背景和基础

ESG 报告的复核不是简单的全文搜索。以“温室气体排放总量”为例，复核人员至少要确认四件事：报告是否披露该指标；数值对应哪一年、哪个主体和哪个口径；单位是否与相邻表格一致；结论能否回到原文页码。实际报告往往长达数十至数百页，信息分散在段落、表格、脚注和附录中。人工逐页查找耗时，纯关键词又容易漏掉同义表达和表格字段。

直接让大模型回答整份 PDF 也没有解决责任问题。回答可以很流畅，但若没有稳定页码、逐字引文和数值来源，复核人员仍要从头翻阅原文。FinQA 等金融文档研究表明，长文档中的文本、表格和多步数值推理需要明确的证据与推理结构 [4]；ESGReveal 等工作也采用检索增强方式处理异构 ESG 报告 [5]。本项目在此基础上进一步把“回答问题”改造成“交付可复核证据”：模型只能在候选原文中抽取，程序再检查页码、区块、引文、数值和单位。

因此，ESG ClaimGuard 要解决的核心问题是：**如何在不牺牲原文可追溯性的前提下，从长篇 ESG 报告中识别指标披露，并把模型输出转化为可查看、可处置、可导出的复核任务。**

ESG ClaimGuard 正式链路



MinerU 与 Qwen 顺序驻留；任何 found 必须回到同报告、同页、同 block 的 canonical 原文


系统端到端流水线

图 1 是全文主线。公开报告先形成可校验的数据清单，经版面解析得到带页码和坐标的区块；ESG-65 指标池从中召回候选；大模型返回固定字段；证据门决定一条结果能否进入正式数据；最后由工作台展示原文、结构化结果和问题处置入口。

项目已经完成 200 份报告的正式运行，共 10,528 页、65 项指标和 13,000 个“报告 × 指标”任务。最终得到 found 7,688 条、missing 5,312 条、error 0。这里的 found 仅表示候选通过内部证据合同，missing 仅表示当前解析与召回范围内没有找到合格证据，二者都不是对企业披露质量的评价。

1.2 场景和价值

目标用户是企业报告编制人员、合规人员和内部审阅团队。一次典型预审从选择报告开始：系统列出需要关注的问题；复核人员查看冲突数值、计算式或缺失提示；点击证据后回到 PDF 原页；最后记录“确认问题、已修正、待补材料、接受风险或判定非问题”等动作，并导出工作底稿。



披露预审与问题处置界面

图 2 是当前系统的实际页面。左侧是同一报告下的问题清单，中间给出问题事实、原文证据和可追溯路径，右侧记录处置。系统将原先散落在搜索、复制和表格登记中的步骤集中到同一界面，但不替代人员作最终判断。

方法	可以完成的工作	仍需解决的问题
关键词或正则	精确复现已知词语	同义表达、表格和上下文覆盖不足
整份 PDF 自由问答	快速概括内容	页码、逐字引文和缺失判断不稳定
普通切块 RAG	返回相关片段并生成回答	通常不强制数值来源和证据合同
ESG ClaimGuard	按指标给出页码、区块、引文、数值来源与处置入口	仍受 OCR、指标口径和人工判断约束

项目价值不在于给出一个看似精确的 ESG 分数，而在于缩短证据定位路径：人员不必从报告第一页开始翻找，可以直接核对系统给出的候选页和原文，把时间用于口径判断和问题处置。

1.3 所需支持

正式版本采用单机顺序运行。MinerU 完成版面解析后释放相关资源，Qwen3.6 再执行抽取，两类模型不同时占用显存。本次正式运行使用 NVIDIA GeForce RTX 5090 (32,607 MiB 显存)、AMD Ryzen Threadripper PRO 9955WX 和 124.8 GiB 内存。网页端采用 React/Vite, 服务端采用 Python。

在其他环境复现完整链路，需要准备有权处理的报告、MinerU 环境、Qwen3.6 模型权重和相应 GPU；只审阅冻结结果、运行 API 和前端不需要重新执行模型。若用于正式监管报送或鉴证业务，还需由法律、审计和行业人员确认适用标准、指标口径和责任边界。

2 项目规划

2.1 整体目标

项目没有把目标写成笼统的“提升 ESG 智能化水平”，而是拆成六个可以验收的问题。

待解决问题	设计目标	仓库中的验收依据
报告来源难追溯	保存公告、PDF、文件哈希和下载状态	data/report_index.csv、download_log.csv
复杂 PDF 难以统一读取	保留页码、区块类型、文本和坐标	解析清单与规范区块数据
指标任务容易漏跑或重复	建立报告与 ESG-65 的完整任务网格	13,000 个唯一键，error 0
大模型输出无法核对	found 必须绑定页码、区块和逐字引文	validation.json、evidence_hardening.json
数值处理不可解释	分开记录值、单位及其来源	正式 CSV/JSON 结果表
结果无法进入实际复核	展示原文、问题、处置和底稿导出	Dashboard 页面、API smoke、测试

2.2 技术创新点

第一，建立“来源—文件—解析区块—抽取结果”的连续数据谱系。每份正式报告都有来源 URL、PDF SHA-256、解析文件 SHA-256；每条 found 又保存 report_id、page_no、block_id 和 evidence_quote。它使问题能够从结构化结果反向追到公开报告原文。

第二，将大模型限制在候选证据内。系统不是把整份报告一次塞入上下文，而是先按版面解析，再利用指标名称、别名和语义相关性召回候选区块。模型负责处理同义表达，程序负责控制输入范围和输出格式。

第三，设置独立于提示词的证据门。found 不由模型一句话决定：指定区块必须存在，页码必须一致，引文必须是该区块原文的连续子串；定量结果还必须保存数值和单位来源。不合格结果进入重试、纠错或保守降级，不直接进入正式 found。

第四，把抽取记录转换为复核流程。系统在声明、证据、可计算约束和适用条款之间建立关系，生成三级问题而不伪造连续风险分数。人员可以查看依据、记录处置并导出底稿，模型结果由此成为工

作对象而不是演示文本。

3 实施方案

3.1 技术可行性分析

技术链条所需的每个环节都有可用基础：巨潮资讯提供公开披露报告及公告元数据；MinerU 可把 PDF 转换为保留版面信息的结构化内容 [2]；Qwen3.6 用于候选内容的结构化抽取 [3]；CSV、JSON、SQLite 和网页 API 能承载可复验结果与处置记录。项目实现的重点不是重新训练基础模型，而是把这些能力组合成受证据约束的完整流程。

风险主要来自数据而非算力。扫描件可能出现 OCR 错字，跨页表格可能丢失表头，报告可能使用不同单位或省略适用范围。系统采用页级区块、候选扩展、精确引文校验、数值来源字段和回原文界面应对；无法消除的不确定性保留为 missing 或问题提示，不自动升级为违规结论。

3.2 技术细节

3.2.1 数据获取、筛选与冻结

本项目的数据入口是巨潮资讯全文检索。下载脚本请求公开检索接口，关键词为“ESG 报告”，按公告时间分页读取。每条公告先检查附件类型和标题，排除摘要、提示性公告、发布通知、英文重复件和明显非 ESG 报告，再从静态附件地址下载 PDF。文件写入临时 .part 后检查 %PDF- 文件头，成功后原子改名，并计算 SHA-256。




图 3 是 2026 年 8 月 31 日重新截取的 actual 检索页。仓库中的 download_cninfo_esg.py 实现

同一检索逻辑。`download_log.csv` 保存 518 条检索处置记录；`report_index.csv` 最终登记 210 份 PDF。正式运行没有直接使用目录中的全部文件，而由 `input_manifest.csv` 冻结其中 200 份，并保存顺序、路径、文件大小、页数和 SHA-256；其余 10 份不参与本文统计。

数据不是一个大而含混的文件夹，而是五层明确对象：

层级	主要格式	关键字段	作用
检索日志	CSV	公告 ID、公司、标题、状	说明条目为何下载或跳过态、错误
报告索引	CSV + PDF	来源 URL、附件 URL、本	连接公开来源与原始文件地路径、SHA-256
冻结队列	CSV	order、report_id、pdf_sha256、expected_pages	固定正式运行范围
规范解析	JSON	page、type、bbox、text/table HTML	保留页码、表格和版面坐标
抽取结果	CSV/JSON	status、value、unit、quote、page_no、block_id、lineage	支撑检索、验证和工作台

3.2.2 问题形式化

设冻结报告集合为 R ，指标集合为 I ，任务集合为 $T = R \times I$ 。本次运行中 $|R| = 200$ 、 $|I| = 65$ ，所以 $|T| = 13,000$ 。对任务 $t = (r, i)$ ，系统输出状态 z 和证据对象 $e = (\text{page}, \text{block_id}, \text{quote})$ ；若结果包含定量值，还输出 v 、 u 及其来源 `origin`。

模型建立在三个假设上：报告可以转为带稳定页码的规范区块；支持一条结果的原文可在一个或少量相邻区块中找到；自动结果只是候选，最终业务判断由人员完成。当扫描损坏、证据跨越大量页面或指标依赖报告外事实时，系统应保守返回 `missing` 或交由人员核对。

3.2.3 版面解析与候选召回

MinerU 将每页内容转换为文本、标题、表格、图片说明等区块，并保存类型和坐标。例如深康佳 A 报告第 43 页的首个规范区块是一个表格，保留了“关键指标—单位—2023 年—2024 年—2025 年”的表头以及温室气体、能源、水和废弃物等行。相比只抽取纯文本，这一结构能避免数值脱离表头和单位。

召回阶段以指标名称、别名及语义相关性筛选区块，只负责缩小搜索空间，不直接判断 `found`。未召回候选表示当前解析与检索条件下证据不足，不等于企业没有披露。

3.2.4 受约束抽取与证据门

Qwen3.6 读取一个指标和其候选区块，返回固定 JSON，包括状态、引文、页码、区块、数值、单位和说明。程序随后执行确定性校验：


```
evidence_valid = block_exists
                    AND page_matches_block
                    AND quote_is_exact_substring_of_block
```

```
final_found = model_returns_found
                    AND evidence_valid
                    AND required_fields_complete
```

证据门不判断披露在业务上是否充分，只验证模型声称引用的文本确实位于指定原文。直接读取、公式推导、原文单位、归一单位和推断单位分别记录；若值由明确表达式得到，结果同时保存推导方法、表达式和输入。

3.2.5 声明约束与问题生成

业务层将一条声明表示为 (subject, metric, period, value, unit, scope, evidence)。系统比较同一报告中的数值、单位和证据关系，形成三类提示：结构化值无法在证据中定位；总量与分项在单位归一后不一致；当前候选范围未找到披露或省略说明。由于主体、期间和 scope 尚未在所有记录中完整结构化，复杂跨声明规则只生成复核候选，不直接定责。

3.2.6 产品 workflow 与工程验证



系统总览与正式数据规模

图 4 是系统总览实际页面，展示冻结正式数据中的 200 份报告、13,000 个任务、59.1% 证据命中和 0 个 error。证据工作台把报告库、PDF 原页、抽取结果、逐字证据和修正表单放在同一屏；预审页则把约束问题与处置记录连接起来。

工程验证覆盖任务唯一性、状态枚举、证据合同、定量来源、manifest 一致性、SHA-256、Python 测试、API smoke 和前端构建。运行中 209 条因证据字段不满足合同而进入异常处置表：193 条在现有候选区块中重新截取了可逐字追溯证据，16 条保守改为 missing。该过程是内部工程纠错，不是独立人工测试集，也不用于计算准确率。

3.3 计划和分工

项目按“需求与指标定义—数据获取—解析与抽取—系统集成—正式运行—材料交付”推进。当前提交的是已经运行并冻结的版本；本节记录实际职责，不再列尚未执行的未来计划。

- **队长：杨哲**——负责项目统筹、需求分析与总体方案，组织指标口径和预审流程设计，协调系统开发、正式运行、成果整合及参赛材料制作。
- **队员 1：邱宇强**——负责公开报告数据整理、MinerU 文档解析、候选召回和大模型抽取，实现证据定位、字段结构化与正式数据运行。
- **队员 2：王恒岳**——负责前后端工作台、证据复核和问题处置功能，实现数据可视化、接口联调、工程测试、运行验证与交付包整理。

4 运行结果与模型评价

4.1 正式运行结果

正式队列包含 200 份报告、10,528 页和 65 项指标。报告与指标形成 13,000 个唯一任务，最终 found 7,688 条、missing 5,312 条、error 0。运行级生成调用为 10,015 次，总墙钟时间 27,928.801 秒。11,280 行结果保存了正 elapsed_seconds，其中位数为 2.765 秒、P95 为 3.683 秒；生成调用数和结果行数属于不同统计层级，不能混用。

验收对象	正式结果	能支持的结论
任务网格	13,000/13,000，重复键 0，error 0	冻结队列全部处理完成
found 证据合同	7,688/7,688	页码、区块和逐字引文在内部数据中可追溯
定量来源字段	3,214/3,214	数值、单位及来源字段完整
运行级调用	10,015 次，调用错误 0	本次单机顺序运行完成
软件验证	测试、API smoke、前端构建通过	提交版功能可运行和复验




图 5 将任务规模与状态放在一起。200×65 恰好等于 13,000，说明结果覆盖完整冻结网格而非抽样展示。error 为 0 说明所有任务都得到最终状态，不代表每个状态都经过独立人工语义判定。




图 6 分开显示运行级调用数与行级耗时。总墙钟还包含召回、重试、写盘和调度，不能用行级中位数直接推算全程时间。

4.2 典型案例

以深康佳 A 2025 年 ESG 报告为例，系统对“温室气体排放总量”返回 113,126.46 吨二氧化碳当量，定位到第 43 页表格区块 **p43:b0**。原文引文为“温室气体排放总量 | 吨二氧化碳当量 | - | 117,319.54 | 113,126.46”，value_origin 和 unit_origin 均为 direct。

4.3 结果分析





图8中环境、社会 and 治理维度的 found/missing 分别为 2,363/2,637、2,550/1,450 和 2,775/1,225。该差异同时受企业披露习惯、指标定义、版面质量和召回策略影响，只能用于估计复核工作量，不能据此评价企业表现。



报告级 found 分布

图 9 按报告汇总 found 数，最小值 0、中位数 42、最大值 57。两端都应优先核对：低值可能来自扫描质量、报告类型或披露较少，高值也可能是宽泛段落被多个指标重复引用。因此报告级分布用于复核排序，不用于排名。




图 10 显示 7,688 条 found 均通过页码、区块和精确子串合同，合同失败数为 0；3,214 条定量 found 均保存 value/unit 来源。它证明正式数据的内部追溯字段完整，但不能证明指标语义判断全部正确。

4.4 模型评价与适用边界

本方案的可用性来自职责分离：MinerU 处理版面，召回模块缩小上下文，Qwen 处理同义表达，证据门验证原文存在，复核人员承担最终判断。出现问题时，可以沿来源 URL、PDF 哈希、解析哈希、页码、区块和结果 ID 定位原因；冻结 manifest 与校验和保证评审看到的文件与正式运行一致。

局限同样明确：OCR 错误可能让正确证据无法通过精确匹配；跨页表格和隐含单位仍需人工拼接；主体、期间和 scope 尚未在所有记录中完整结构化；当前没有独立人工测试集，因此本文不能回答语义准确率是多少，也不能宣称优于其他模型。系统适合报告发布前的证据定位和内部预审，不适合直接给出企业评分、违规结论、投资建议或法定鉴证意见。

4.5 结论

ESG ClaimGuard 回答了一个具体问题：怎样把长篇 ESG 报告中的候选披露，整理成复核人员能够直接核对的证据任务。项目从公开公告出发，保存来源与文件哈希；从 PDF 中保留页码、表格和坐标；用指标召回和大模型生成结构化候选；再以确定性证据门检查原文位置；最后在网页中展示问题、原文和处置记录。

在冻结的 200 份报告上，13,000 个任务全部得到最终状态，7,688 条 found 可以沿内部数据回到指定页码和区块，3,214 条定量结果保存了数值与单位来源。结合实际工作台页面，这些结果说明“公开报告输入—证据候选—问题处置—底稿导出”的工程流程已经跑通。

项目没有把工程完成偷换成模型准确，也没有把 missing 偷换成企业未披露。它的实际作用是先

完成大规模、重复性的定位和整理，把证据是否充分、口径是否一致以及问题如何处置留给复核人员。这正是系统在报告发布前预审场景中的价值。

5 参考资料

1. 中国研究生人工智能创新大赛组委会. 第八届中国研究生人工智能创新大赛初赛作品提交规范及项目文档模板, 2026.
2. Wang B. et al. MinerU: An Open-Source Solution for Precise Document Content Extraction. arXiv:2409.18839, 2024. DOI: 10.48550/arXiv.2409.18839.
3. Qwen Team. Qwen3.6-27B Model Card. Hugging Face model repository, 2026.
4. Chen Z. et al. FinQA: A Dataset of Numerical Reasoning over Financial Data. EMNLP 2021, pp. 3697–3711. DOI: 10.18653/v1/2021.emnlp-main.300.
5. Zou Y. et al. ESGReveal: An LLM-based Approach for Extracting Structured Data from ESG Reports. arXiv:2312.17264, 2023.
6. Bronzini M. et al. Glitter or Gold? Deriving Structured Insights from Sustainability Reports via Large Language Models. arXiv:2310.05628, 2023.
7. 巨潮资讯网. 上市公司公告全文检索与 PDF 附件服务. <https://www.cninfo.com.cn/>.
8. 项目数据来源、软件版本、许可证和原创边界详见随附《来源与借鉴台账》《第三方依赖与许可》以及冻结数据的 provenance 目录。