

上海工程技术大学

第十七届研究生数学建模竞赛

参赛队号 B202617002

1. 杨哲

队员姓名 2. 邱宇强

3. 王恒岳

上海工程技术大学第十七届

研究生数学建模竞赛

题目： ESG 报告数据智能提取与分析：证据约束型长文档结构化抽取模型

摘要：

上市公司 ESG 报告通常以长 PDF 形式披露，具有页数多、表格与正文混排、指标口径差异大、定量与定性信息并存等特点。本文将赛题中的 ESG 指标识别任务抽象为 report-indicator 证据约束型结构化抽取问题：给定报告集合 D 与指标集合 Q ，对每一对 (d_i, q_j) 先在解析后的内容块空间中召回候选证据，再由大语言模型在候选证据范围内输出固定 JSON 结构，并保留 evidence_quote、page_no 与 block_id 以支持复核。

本文使用 200 份 A 股、北交所及港股上市公司 ESG 类 PDF 报告，构建 65 个覆盖 E、S、G 三个维度的指标，其中定量指标 35 个、机制性布尔指标 15 个、定性描述指标 15 个。MinerU 解析结果形成 10528 页、17740555 个 Markdown 字符和 235662 个内容块。全量构造 13000 个 report-indicator 任务，运行结果中 found 为 7777 条、missing 为 5223 条、error 为 0 条；该分布用于描述结构化抽取输出状态，不作为人工标注评价结论。进一步地，本文设计后处理与质量诊断规则，识别 value/unit 缺失、比例误作数量、金额误作数量、零事件归一、证据过短和标题式机制证据等风险，并通过 Streamlit 复核系统将结果查看、证据定位、风险样本与 CSV 下载串联为可追溯闭环。

关键字： ESG 报告 长文档抽取 证据约束 候选证据召回 结构化信息抽取 质量诊断

目录

1. 问题重述	4
1.1 ESG 报告结构化抽取任务	4
1.2 定量、定性与机制性指标差异	4
1.3 研究目标与边界	4
2. 数据集与文档特征分析	5
2.1 报告来源与样本构成	5
2.2 PDF 页数、文本与版面元素	6
2.3 文档特征对建模的影响	7
3. 问题分析与建模思路	8
3.1 长文档抽取难点	8
3.2 总体技术路线	8
4. 模型假设与符号说明	9
4.1 模型假设	9
4.2 符号说明	9
5. 模型建立	10
5.1 PDF 结构化解析与内容块表示	10
5.2 ESG-65 指标体系建模	10
5.3 report-indicator 任务定义	11
5.4 候选证据召回模型	11
5.5 大语言模型证据约束抽取模型	11
5.6 后处理规则与质量诊断模型	12
5.7 交互式复核系统设计	13
6. 模型求解与实现	15
6.1 求解流程	15
6.2 批量求解策略	15
7. 实验结果与分析	17
7.1 全量抽取结果	17
7.2 E/S/G 维度结果分析	17
7.3 指标类型结果分析	19
7.4 定量字段与运行耗时	20
7.5 风险样本分析	20
7.6 典型抽取案例	20
7.7 系统展示与复核流程	22
8. 模型评价	23
8.1 模型优点	23
8.2 局限性	23
8.3 改进方向	23
9. 结论	23
10. 参考文献	24

附录 A 关键模型代码	25
1.1 内容块构造与候选召回	25
1.2 证据约束抽取与后处理	25

1. 问题重述

1.1 ESG 报告结构化抽取任务

赛题要求围绕上市公司 ESG 报告完成数据采集、预处理、指标体系构建、定量与定性指标识别、结构化输出和结果展示。ESG 报告披露实践受到 GRI、ISSB 和 TCFD 等框架影响[1-3]，但企业实际报告不同于单一表格数据源，其披露内容分散在正文、表格、章节标题、指标索引和附录中，同一指标在不同公司之间也常使用不同名称、单位和叙述方式。因此，本文不把任务处理为整篇文档问答，而是建模为可定位证据驱动的结构化抽取问题。

1.2 定量、定性与机制性指标差异

定量指标要求识别数值及单位，例如温室气体排放总量、能源消耗总量、员工培训小时数等；定性指标要求保留语义完整的原文片段，例如 ESG 战略、绿色产品与服务、员工权益保障等；机制性布尔指标关注报告是否披露制度、措施或治理安排，例如反腐败机制、ESG 治理架构和碳排放管理措施。三类指标的证据形态不同，决定了后续候选召回、字段约束和风险规则不能采用同一模板。

1.3 研究目标与边界

本文研究目标是从公开 ESG PDF 报告中形成可追溯的结构化结果，而非对企业 ESG 表现进行评分、排名或投资判断。输出字段保留 `evidence_quote`、`page_no`、`block_id` 和 `risk_tag`，使评审者可以从结构化数据回到报告证据。模型评价侧重运行结果分布、字段完整性、风险样本和复核闭环；在缺少完整人工真值集的前提下，不把自动运行状态解释为人工标注层面的评价指标。

2. 数据集与文档特征分析

2.1 报告来源与样本构成

本文采集并整理 200 份上市公司 ESG 类 PDF 报告。报告标识中可可靠提取证券代码、公司简称、年份和报告类型，由此得到 200 个唯一证券代码和 198 个公司简称。样本中 2025 年报告 196 份，2026 年报告 4 份；代码形态上，A 股或北交所代码 182 份，港股代码 18 份；报告类型包括 ESG 报告 171 份、可持续发展报告 18 份、ESG 暨社会责任报告 11 份。现有元数据未提供可靠行业字段，因此本文不作行业分布扩展解释。

表 1 数据集与解析规模摘要

项目	数值
原始 PDF	200
公司数（文件名）	198
唯一证券代码	200
解析成功报告	200
解析总页数	10528
Markdown 总字符数	17740555
表格标记总数	6713
图片引用总数	30465

样本报告类型构成





图 2-1 样本报告类型构成



(a) 报告年份分布 (b) 市场代码类型分布

图 2-2 样本年份与市场代码类型分布

2.2 PDF 页数、文本与版面元素

MinerU 解析 manifest 记录 200 份报告均形成可用 Markdown，解析成功比例为 1.0000。解析页数总计 10528 页，单份报告页数最少 1 页、最多 130 页，平均 52.64 页，中位数 51.5 页。Markdown 字符总量为 17740555，平均每份 88702.77 字符。manifest 中表格标记总数为 6713，图片引用总数为 30465，说明 ESG 报告的主体信息并非只存在于连续正文中。

MinerU 解析产物规模





图 2-3 MinerU 解析产物规模

进一步展开解析后的块级结构，本文得到 235662 个内容块，平均每份报告 1178.31 个。主要块类型包括 paragraph 83390 个、title 51806 个、page_header 42113 个、image 28123 个、page_number 15692 个、table 6455 个。内容块数量与类型分布表明，直接把整份 PDF 输入语言模型会引入大量无关上下文，而只按关键词搜索又容易丢失表格和章节上下文。

内容块类型分布（前十类）



数据来源：项目既有结构化输出统计生成

图 2-4 内容块类型分布

2.3 文档特征对建模的影响

ESG 报告的结构化难点主要来自四方面。第一，长文档中同一指标可能在目录、章节标题、正文解释、表格和附录中重复出现，证据位置需要被区分。第二，定量指标常在表格中披露，单位可能位于表头或同一行附近，value 与 unit 的绑定依赖局部上下文。第三，定性指标需要保留完整机制描述，过短证据会降低复核价值。第四，不同行业和公司披露口径不同，关键词只能提供候选线索，不能直接替代语义判断。因此本文采用“内容块建模-候选证据召回-证据约束抽取-质量诊断”的链式方法。

3. 问题分析与建模思路

3.1 长文档抽取难点

设第 i 份报告为 d_i ，其解析后的内容块集合为 B_i 。若对整篇报告直接进行抽取，模型需要在数万字符甚至十余万字符中寻找某一指标证据，成本高且难以保证证据位置。若只使用规则抽取，则同义表述、跨表头单位、政策描述和零事件表达难以覆盖。本文将大语言模型放在候选证据范围内使用，使其承担局部语义抽取，而不承担无约束生成。

3.2 总体技术路线

本文技术路线如图 3-1 所示。报告首先通过 MinerU 转换为 Markdown、JSON 和图片资源，再展开为带页码、块号、类型和文本的内容块序列；随后将 65 个 ESG 指标与 200 份报告组合为 13000 个 report-indicator 任务；每个任务通过关键词、单位、块类型和位置等线索召回候选证据；候选为空时直接输出 missing，候选非空时由 qwen3 在证据约束下输出 JSON；最后通过后处理、质量诊断和 Streamlit 系统形成复核闭环。

证据约束型 ESG 长文档结构化抽取技术路线



流程图遵循 Figure Contract：每个节点对应可追溯的数据文件或输出表。

图 3-1 证据约束型 ESG 长文档结构化抽取技术路线

4. 模型假设与符号说明

4.1 模型假设

本文模型建立在以下假设之上：

1. 公开 ESG 报告内容可用于赛题范围内的算法验证。
2. MinerU 解析结果能保留主要文本、表格文本、页码和块顺序。
3. report-indicator 判断必须基于候选证据；候选证据不足时不补写结果。
4. ESG-65 指标体系覆盖本文任务所需主要披露类型，但不声称覆盖全部 ESG 披露项。
5. 自动质量诊断用于组织复核优先级，不等同于完整人工真值集。
6. 本文不建立 ESG 评分、排名或投资建议模型。

4.2 符号说明

表 2 主要符号说明

符号	含义	说明
D	报告集合	$D = \{d_1, d_2, \dots, d_n\}$, 本文 $n = 200$
d_i	第 i 份报告	原始 PDF 及其解析产物
B_i	内容块集合	第 i 份报告解析后的块序列
b_{ik}	内容块	包含 report_id、page_no、block_id、block_type、text
Q	指标集合	ESG-65 指标体系
q_j	第 j 个指标	包含维度、类型、关键词、单位候选和风险标记
K_j	关键词集合	指标 q_j 的候选召回词集合
U_j	单位候选集合	定量指标的单位约束集合
$s(b, q)$	候选评分	内容块 b 对指标 q 的证据相关性
E_{ij}	候选证据集合	报告 d_i 对指标 q_j 的 Top-k 证据块
F	证据约束抽取函数	在 E_{ij} 范围内输出结构化记录
R_j	后处理规则	与指标类型和风险标记相关的字段检查规则
y_{ij}	输出记录	report-indicator 结构化结果

5. 模型建立

5.1 PDF 结构化解析与内容块表示

PDF 不是天然面向结构化抽取的数据格式,文档智能研究通常需要先处理版面分析、表格抽取和内容顺序恢复等问题[4-5]。本文使用 MinerU 将 PDF 转换为 JSON、Markdown 和图片资源[6], 其中 Markdown 便于文本检索, JSON 保留块级结构, 图片资源保留图表和版面证据。每个内容块定义为

$$b_{ik} = (report_id, page_no, block_id, block_type, text), \quad (1)$$

第 i 份报告的证据空间表示为

$$B_i = \{b_{i1}, b_{i2}, \dots, b_{im_i}\}. \quad (2)$$

表格块对定量指标尤其重要, 因为 value 与 unit 往往在同一表格行、列标题或相邻单元格中出现。标题块和段落块则更多服务于定性、机制性指标的证据定位。

PDF 到内容块的结构化表示模型



内容块是后续召回、抽取和复核定位的最小证据单元。

图 5-1 PDF 到内容块的结构化表示模型

5.2 ESG-65 指标体系建模

指标体系 Q 由赛题要求、ESG 报告高频披露项和前序质检结果共同约束, 包含 E 维度 25 个、S 维度 20 个、G 维度 20 个; 按类型划分, 定量指标 35 个、机制性布尔指标 15 个、定性描述指标 15 个。每个指标表示为


$$q_j = (id_j, name_j, dim_j, type_j, K_j, U_j, risk_j). \quad (3)$$

其中 K_j 为关键词集合, U_j 为单位候选集合, $risk_j$ 用于标记需重点复核的指标或字段。定量指标输出 value 和 unit, 定性指标输出 qualitative_text, 机制性布尔指标输出 true/false 与原文机制证据。

表 3 ESG-65 指标体系维度分布

项目	E	S	G	合计
指标数	25	20	20	65

ESG-65 指标体系结构



数据来源：项目既有结构化输出统计生成

图 5-2 ESG-65 指标体系结构

5.3 report-indicator 任务定义

对每份报告 d_i 和每个指标 q_j 构造一个任务，输出结构化记录

$$y_{ij} = (\text{status}, \text{value}, \text{unit}, \text{qualitative_text}, \text{evidence_quote}, \text{page_no}, \text{block_id}, \text{risk_tag}). \quad (4)$$

其中 $\text{status} \in \{\text{found}, \text{missing}, \text{error}\}$ 。**found** 表示在候选证据约束下生成了结构化字段，**missing** 表示当前证据不足以支持该指标披露，**error** 表示流程异常。该状态集合描述自动抽取流程的运行输出，不表示人工标注评价结论。

5.4 候选证据召回模型

候选召回的目标是在长文档中缩小语义抽取范围。对内容块 b 与指标 q ，定义候选评分


$$s(b, q) = w_k \text{match}_K(b, q) + w_u \text{match}_U(b, q) + w_t \text{type_score}(b) + w_p \text{position_score}(b). \quad (5)$$

match_K 衡量关键词命中， match_U 衡量单位候选命中， type_score 对表格、段落和标题等块类型赋予差异权重， position_score 反映标题邻近、章节上下文和块序位置等线索。每个任务选择 Top-k 内容块构成 E_{ij} 。当 E_{ij} 为空时，流程直接输出 **missing**；当 E_{ij} 非空时，才进入模型抽取链路。该设计降低了长文档噪声，也减少了模型调用规模。

5.5 大语言模型证据约束抽取模型

本文使用 qwen3 作为候选证据范围内的语义抽取器，调用方式通过本地 Ollama 服务完成[7-8]。这一设计与检索增强生成思想相近[9]，但本文的重点不是开放式生成，而

候选证据召回与抽取链路漏斗




数据来源：项目既有结构化输出统计生成

图 5-3 候选证据召回与抽取链路漏斗

是在局部候选证据内输出可复核字段。模型输入由当前 report-indicator 任务、指标定义和候选证据组成，不使用报告外知识。抽取约束包括：证据不足必须 missing；定量 found 必须包含 value 和 unit；定性 found 保留原文语义片段；机制性布尔 found 必须有制度、措施或治理安排证据；evidence_quote 必须来自候选证据；输出必须符合固定 JSON schema。

候选证据约束抽取与 JSON 输出



模型只在候选证据范围内抽取，输出字段用于可追溯复核。

图 5-4 候选证据约束抽取与 JSON 输出

5.6 后处理规则与质量诊断模型

模型输出后，系统进行 JSON 解析、字段补齐、value/unit 检查、单位修复、零事件归一和风险标记。质量诊断不把样本判为最终对错，而是识别复核优先级。风险类型包

括 value/unit 缺失、比例误作数量、金额误作数量、零事件归一、证据过短和标题式机制证据。risk_tag 记录具体触发规则，risk_level 用 high、medium、low 表示复核优先级，caution_tag 用于提示高风险指标或需要人工关注的样本。

后处理、质量诊断与交互式复核闭环



风险样本用于组织复核优先级，不替代完整人工真值集。

图 5-5 后处理、质量诊断与交互式复核闭环

5.7 交互式复核系统设计

Streamlit 系统不是附属截图，而是结构化结果的复核出口[10]。系统数据源为结构化 JSON，提供系统总览、公司视角、指标视角、证据核验、高风险样本和新报告接入六个页面。公司视角用于查看单份报告的 65 个指标结果，指标视角用于横向比较同一指标在 200 份报告中的披露情况，证据核验页面绑定 evidence_quote、page_no 和 block_id，高风险样本页面用于集中处理 risk_tag 与 risk_level，下载功能支持将筛选结果导出为 CSV。

Streamlit 可追溯复核系统功能架构



系统页面直接绑定结构化字段，形成结果查看、定位和下载闭环。

图 5-6 Streamlit 可追溯复核系统功能架构




图 5-7 Streamlit 系统总览页面截图

ESG 智能提取与质量核验系统

基于既有 200 份抽取结果的证据追溯、质量诊断和抽样复核辅助；不等于人工标注评价结论。

系统总览 公司视角 指标视角 证据核验 高风险样本 新报告接入

公司视角

选择 report_id

000016_深康佳 A_2025_ESG报告

found=50, missing=15, error=0

	indicator_name	dimension	indicator_type	status	value	unit	evidence_quote	page_no	block_id
0	温室气体排放总量	E	quantitative	found	117,319.54	吨二氧化碳当量	温室气体排放总量 吨二氧化碳当量 117,319.54 113,126.46	15	000016_深康佳
1	温室气体排放强度	E	quantitative	found	16.11	吨二氧化碳当量/	温室气体排放强度 吨二氧化碳当量/百万营收 16.11 16.49	15	000016_深康佳
2	碳排放管理措施	E	boolean	found	true		康佳高度重视气候变化带来的机遇与挑战，扎实推进碳排放管理工作，以EHSQ管	13	000016_深康佳
3	气候风险管理	E	boolean	found	true		基于气候相关财务信息披露工作组（TCFD）的披露建议与要求完善气候变化风险	14	000016_深康佳
4	能源消耗总量	E	quantitative	found	3.21	万吨标准煤	能源消耗总量 万吨标准煤 3.21 3.50	15	000016_深康佳
5	耗电量	E	quantitative	found	14229.84	万千瓦时	电力消耗量 14,229.84万千瓦时	19	000016_深康佳
6	燃料消耗量	E	quantitative	found	114.94	吨	汽油消耗量 114.94吨	42	000016_深康佳
7	总用水量	E	quantitative	found	148.27	万吨	新鲜水用水量 万吨 - 114.63 148.27	43	000016_深康佳
8	化学需氧量排放量	E	quantitative	found	36.54	吨	化学需氧量排放量 36.54 吨 ± 8.13%	17	000016_深康佳
9	氨氮排放量	E	quantitative	found	4.5	吨	氨氮排放量 4.5 吨 ± 30.47%	17	000016_深康佳
10	废弃物产生量	E	quantitative	found	18,725.42	吨	一般废弃物产生量 18,725.42吨	18	000016_深康佳
11	危险废物产生量	E	quantitative	found	3,851	吨	危险废物产生量 3,851吨	18	000016_深康佳
12	一般废弃物产生量	E	quantitative	found	18,725.42	吨	一般废弃物产生量 18,725.42吨	18	000016_深康佳
13	废弃物回收利用量	E	quantitative	missing					
14	大气污染物排放	E	quantitative	found	0.49	吨	二氧化硫排放量 0.49吨 ± 48.45%	18	000016_深康佳
15	氮氧化物排放量	E	quantitative	found	32.57	吨	氮氧化物排放量 32.57吨 ± 3.21%	18	000016_深康佳
16	挥发性有机物排放	E	quantitative	found	13.64	吨	挥发性有机物排放量 13.64吨 ± 12.44%	18	000016_深康佳

图 5-8 Streamlit 公司视角页面截图

6. 模型求解与实现

6.1 求解流程

模型求解过程由四个阶段组成。第一阶段是块级证据空间构造，将报告解析结果统一表示为有序内容块集合 B_i ；第二阶段是任务展开，将每份报告与 ESG-65 指标逐一组合为 report-indicator 任务；第三阶段是证据召回与约束抽取，先用 $s(b, q)$ 选择候选证据，再在候选证据范围内完成结构化字段抽取；第四阶段是后处理和质量诊断，对字段完整性、证据长度、单位语境和机制性证据进行规则检查。

6.2 批量求解策略

批量求解对每份报告遍历全部指标。若候选证据为空，则记录 missing 并保留候选数；若候选非空，则进入证据约束抽取，解析 JSON，执行字段归一和后处理。异常情况包括 JSON 解析失败、字段缺失、证据为空、value/unit 不完整和模型返回异常；对应样本进入 error 或风险诊断链路。正式批次中 error 为 0，说明该批次未出现未恢复的流程异常。

ESG 智能提取与质量核验系统

基于既有 200 份抽取结果的证据追溯、质量诊断和抽样复核辅助；不等于人工标注评价结论。

系统总览 公司视角 指标视角 证据核验 高风险样本 新报告接入

指标视角

选择 indicator_name

ESG 战略目标 [g_esg_strategy]

found	missing	error	found 率
119	81	0	59.50%

数值样例

	report_id	value	unit	evidence_quote	page_no	block_id
307	000526_学大教育_2025_ESG报告	true		董事会是ESG治理的最高决策机构,为ESG管理及公开披露的最高责任机构,主要职	11	000526_学大教育_2025_ESG报告:p11:b0
567	000598_兴蓉环境_2025_ESG报告			兴蓉环境将董事会作为ESG事宜的最高决策机构,并将ESG纳入公司战略委员会工	6	000598_兴蓉环境_2025_ESG报告:p6:b30
697	000720_新能泰山_2025_ESG报告			新能泰山构建了董事会领导、专门委员会指导、推进小组统筹执行的三级ESG治	9	000720_新能泰山_2025_ESG报告:p9:b17
827	000777_中核科技_2025_ESG暨社会责任报告			中核科技立足行业特性,围绕联合国可持续发展目标 (SDGs),积极开展 ESG实	10	000777_中核科技_2025_ESG暨社会责任报告
892	000810_创维数字_2025_ESG报告			公司制定《环境、社会与治理 (ESG) 委员会工作细则》《董事会 ESG 工作议事	8	000810_创维数字_2025_ESG报告:p8:b3
1022	000881_中广核技_2025_ESG报告			董事会参与环境、社会和公司治理重大事项的审议与决策,对公司的ESG战略及	7	000881_中广核技_2025_ESG报告:p7:b5
1152	000923_河钢资源_2025_ESG报告			公司设立ESG委员会,ESG委员会在董事会领导下开展工作,对董事会负责,委	9	000923_河钢资源_2025_ESG报告:p9:b3
1317	000966_苏泊尔_2025 ESG报告			苏泊尔高度重视环境、社会及治理的可持续发展,在经营活动中,上市公司自觉	10	000966_苏泊尔_2025 ESG报告:p10:b5

风险样本

	report_id	status	value	unit	evidence_quote	risk_tag	risk_level	caution_tag	suspected_issue_type	risk_reason
										empty

图 5-9 Streamlit 指标视角页面截图

表 4 模型求解阶段与输入输出

阶段	输入	输出	建模作用
内容块表示	PDF 解析文本、表格、页码	B_i	将长文档转化为可定位证据空间
指标任务展开	报告集合 D 、指标集合 Q	$\{b_{i1}, \dots, b_{im_i}\}$	明确每份报告对每个指标的抽取目标
候选证据召回	内容块 B_i 、指标 q_j	候选集合 E_{ij}	降低长文档噪声，限定模型上下文
约束抽取	任务定义、候选证据	结构化记录 y_{ij}	输出状态、数值、单位、证据和定位字段
质量诊断	结构化记录与证据字段	风险标签与复核优先级	标记字段缺失、证据不足和语境误用风险

ESG 智能提取与质量核验系统

基于既有 200 份抽取结果的证据追溯、质量诊断和抽样复核辅助；不同于人工标注评价结论。

系统总览 公司视角 指标视角 证据核验 高风险样本 新报告接入

证据核验

dimension

全部

indicator_type

全部

status

全部

risk_tag

全部

report_id 包含

indicator_name 包含

匹配 13000 条

下载筛选结果 CSV

	report_id	indicator_name	dimension	indicator_type	status	value	unit	evidence_quote
0	000016_深康佳 A_2025_ESG报告	温室气体排放总量	E	quantitative	found	117,319.54	吨二氧化碳当量	温室气体排放总量 吨二氧化碳当量 117,319.54 113,126.46
1	000016_深康佳 A_2025_ESG报告	温室气体排放强度	E	quantitative	found	16.11	吨二氧化碳当量/百万营收	温室气体排放强度 吨二氧化碳当量/百万营收 16.11 16.49
2	000016_深康佳 A_2025_ESG报告	碳排放管理措施	E	boolean	found	true		康佳高度重视气候变化带来的机遇与挑战，扎实推进碳排放管理工作，以
3	000016_深康佳 A_2025_ESG报告	气候风险管理	E	boolean	found	true		基于气候相关财务信息披露工作组（TCFD）的披露建议与要求完善气候
4	000016_深康佳 A_2025_ESG报告	能源消耗总量	E	quantitative	found	3.21	万吨标准煤	能源消耗总量 万吨标准煤 3.21 3.50
5	000016_深康佳 A_2025_ESG报告	耗电量	E	quantitative	found	14229.84	万千瓦时	电力消耗量 14,229.84万千瓦时
6	000016_深康佳 A_2025_ESG报告	燃料消耗量	E	quantitative	found	114.94	吨	汽油消耗量 114.94吨
7	000016_深康佳 A_2025_ESG报告	总用水量	E	quantitative	found	148.27	万吨	新鲜水用水量 万吨 - 114.63 148.27
8	000016_深康佳 A_2025_ESG报告	化学需氧量排放量	E	quantitative	found	36.54	吨	化学需氧量排放量 36.54吨 + 8.13%
9	000016_深康佳 A_2025_ESG报告	氨氮排放量	E	quantitative	found	4.5	吨	氨氮排放量 4.5吨 + 30.47%
10	000016_深康佳 A_2025_ESG报告	废弃物产生量	E	quantitative	found	18,725.42	吨	一般废弃物产生量 18,725.42吨
11	000016_深康佳 A_2025_ESG报告	危险废弃物产生量	E	quantitative	found	3,851	吨	危险废弃物产生量 3,851吨
12	000016_深康佳 A_2025_ESG报告	一般废弃物产生量	E	quantitative	found	18,725.42	吨	一般废弃物产生量 18,725.42吨
13	000016_深康佳 A_2025_ESG报告	废弃物回收利用率	E	quantitative	missing			
14	000016_深康佳 A_2025_ESG报告	大气污染物排放	E	quantitative	found	0.49	吨	二氧化硫排放量 0.49吨 + 48.45%
15	000016_深康佳 A_2025_ESG报告	氮氧化物排放量	E	quantitative	found	32.57	吨	氮氧化物排放量 32.57吨 + 3.21%
16	000016_深康佳 A_2025_ESG报告	挥发性有机物排放量	E	quantitative	found	13.64	吨	挥发性有机物排放量 13.64吨 + 12.44%
17	000016_深康佳 A_2025_ESG报告	颗粒物排放量	E	quantitative	missing			

图 5-10 Streamlit 证据核验页面截图

7. 实验结果与分析

7.1 全量抽取结果

全量求解得到 13000 条 report-indicator 记录，对应 200 份报告与 65 个指标。运行结果中 found 7777 条、missing 5223 条、error 0 条；候选为空直接 missing 的任务为 2958 条，候选非空并进入模型判断链路的任务为 10042 条。found 样本中 page_no 缺失 0 条、block_id 缺失 0 条，说明可追溯定位字段在 found 结果中保持完整。

7.2 E/S/G 维度结果分析

任务构成中 E 维度 5000 条，S 维度 4000 条，G 维度 4000 条；found 分布为 E 维度 2331 条、S 维度 2574 条、G 维度 2872 条。G 维度 found 数较高，主要因为治理结构、董事会、审计、反腐败等内容往往以固定章节和制度性表述出现，关键词召回更容易获得完整段落证据。S 维度位于中间，员工权益、供应链管理和公益投入等指标常见于社会责任章节，但员工培训、工伤、安全投入等定量指标仍依赖表格和单位。E 维度 found 数较低，并不意味着企业环境披露质量较差，而是因为 E 维度定量指标更多，且污染物、能源、水耗、废弃物等指标在不同行业中披露口径差异大；当报告只给出政策表述或未给出单位化数值时，证据约束模型会更倾向输出 missing。

ESG 智能提取与质量核验系统

基于既有 200 份抽取结果的证据追溯、质量诊断和抽样复核辅助；不等于人工标注评价结论。

系统总览 公司视角 指标视角 证据核验 高风险样本 新报告接入

高风险样本

risk_level

high

medium

指标名包含

风险类型

全部

匹配 108 条

	risk_level	suspected_issue_type	risk_tag	caution_tag	indicator_name	report_id	status	value	unit	evidence_quote
0	high	value_unit_missing	value_unit_missing	high_risk_indicator	董事会多元化	600278_东方创业_2025_ESG报告	found	7.2		董事会成员男女比
1	high	value_unit_missing	value_unit_missing		独立董事占比	600278_东方创业_2025_ESG报告	found	6.3		非独立董事和独立
2	high	value_unit_missing	value_unit_missing		独立董事占比	600783_鲁信创投_2025_ESG报告	found	2		独立董事2位 非独
3	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	董事会人数	000503_国新健康_2025_ESG报告	found	9	人	公司董事会由9名董
4	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	000557_西部创业_2025_可持续发展报告	found	100%	%	客户投诉处理率 1
5	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	000810_创维数字_2025_ESG报告	found	100	%	客户投诉问题整改
6	high	possible_rate_as_count	possible_rate_as_count		董事会人数	002011_盾安环境_2025_ESG报告	found	9	人	截至本报告期末，
7	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	002533_金杯电工_2025_ESG报告	found	100%	%	2025年,公司未发生
8	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	董事会人数	002649_博彦科技_2025_ESG报告	found	7	人	截至2025年底,公
9	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	董事会人数	300035_中科电气_2025_ESG报告	found	9	人	2025年,董事会共
10	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	300149_睿智医药_2025_ESG报告	found	100%	%	投诉处理率 100%
11	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	董事会人数	300212_易华录_2025_ESG报告	found	9	名	截至报告期末,公
12	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	300468_四方精创_2025_ESG报告	found	100	%	客户投诉及时处理
13	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	301073_君亭酒店_2025_ESG报告	found	90	次	2025年,本集团及
14	high	possible_rate_as_count	possible_rate_as_count		董事会人数	301308_江波龙_2025_ESG报告	found	9	名	江波龙董事会由9
15	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	301599_理奇智能_2025_ESG报告	found	0.338	%	质量投诉发生率 5
16	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	董事会人数	600009_上海机场_2025_ESG报告	found	7	人	公司董事会成员共
17	high	possible_rate_as_count	possible_rate_as_count	high_risk_indicator	客户投诉	600000_上海机场_2025_ESG报告	found	100	%	2025年,上海机场

图 5-11 Streamlit 高风险样本页面截图

表 5 全量抽取结果摘要

项目	数值
report-indicator 任务	13000
found	7777
missing	5223
error	0
候选为空直接 missing	2958
进入模型判断链路	10042
后处理修复	109
具体风险样本	164


13,000 个 report-indicator 任务结果分布



数据来源：项目既有结构化输出统计生成

图 7-1 13,000 个 report-indicator 任务结果分布

E/S/G 维度任务与 found 分布



数据来源：项目既有结构化输出统计生成


图 7-2 E/S/G 维度任务与 found 分布

7.3 指标类型结果分析

按类型看，定量任务 7000 条，found 3217 条；机制性布尔任务 3000 条，found 2244 条；定性任务 3000 条，found 2316 条。定量指标 found 比例相对较低，原因在于其同时要求指标名、数值和单位三类证据闭合：表格表头缺失、单位位于上一行、同一表格含多年度数值、百分比与人数混排，都会使模型难以在证据范围内给出稳定输出。定性指标和机制性布尔指标的证据通常是段落文本，候选召回更容易命中；但二者的风险不同。定性指标的主要问题是证据片段可能过短，不能完全支撑结论；机制性布尔指标的主要问题是标题、目录或章节名含有“治理架构”“反腐败”等词，但正文未给出制度或措施内容，此时若直接判定 true，就会形成标题式机制误判。因此，本文在 schema 约

束中要求布尔 found 必须给出机制、制度或行动证据，并在质量诊断中单独设置标题式机制风险。

指标类型任务与 found 分布



数据来源：项目既有结构化输出统计生成

图 7-3 指标类型任务与 found 分布

7.4 定量字段与运行耗时


质量指标显示，定量 found 中 value 缺失 0 条，unit 缺失 3 条，定量字段不完整 3 条；证据为空 0 条，证据过短 27 条；后处理修复 109 条。这说明字段约束对定量输出有明显筛选作用：当证据无法同时支撑数值和单位时，多数样本被保守地留在 missing 或风险样本中，而不是生成不可核验数值。耗时记录显示，逐任务记录字段求和为 9064.17 秒，平均 0.70 秒；正式批处理墙钟耗时为 4930.803 秒。两种口径分别反映任务级记录和批处理总运行时间，不能直接相互替代。

7.5 风险样本分析

质量诊断共识别 164 个具体风险样本，其中 high 36 个、medium 72 个、low 56 个。按风险类型看，零事件归一 56 个、证据过短 39 个、标题式机制证据 33 个、比例误作数量 32 个、value/unit 缺失 3 个、金额误作数量 1 个。这些样本不是最终错误集，而是用于复核排序的风险集合。零事件风险集中出现，是因为 ESG 报告常用“未发生重大安全事故”“无工亡”等自然语言表达，系统需要将其归一为 0，但仍需确认事件边界。比例误作数量风险主要来自“女性董事占比”“独立董事比例”等语境，这些百分比不应被抽成董事人数或事故次数。标题式机制风险则反映 boolean 指标的典型难点：标题能说明报告有相关章节，但不能单独证明企业建立了制度或执行了措施。

7.6 典型抽取案例


质量诊断风险类型分布



数据来源：项目既有结构化输出统计生成

图 7-4 质量诊断风险类型分布

风险等级与复核样本结构



数据来源：项目既有结构化输出统计生成

图 7-5 风险等级与复核样本结构

表 6 典型抽取与风险样本

案例类型	指标	抽取输出	原文证据摘录	复核说明
定量抽取	温室气体排放总量	117,319.54 吨二氧化碳当量	温室气体排放总量 吨二氧化碳当量 117,319.54 113,126.46	表格证据同时给出指标名、数值和单位。

案例类型	指标	抽取输出	原文证据摘录	复核说明
定性抽取	绿色产品与服务	多款核心产品通过绿色产品认证，推动绿色产品认证工作，将绿	多款核心产品通过绿色产品认证，推动绿色产品认证工作，将绿色低碳理念融入产品的设计开发、生产制造、回收利用等环...	原文片段能够支撑定性描述。
机制判定	碳排放管理措施	true	康佳高度重视气候变化带来的机遇与挑战，扎实推进碳排放管理工作，以 EHSQ 管理体系为支撑，成立 EHSQ 委员会，...	证据包含机制、组织或措施，不只是标题。
单位缺失风险	董事会多元化	7:2	董事会成员男女比例为 7:2	输出缺少单位或单位语境不完整，需核对表头。
单位缺失风险	独立董事占比	6:3	非独立董事和独立董事比例为 6:3	输出缺少单位或单位语境不完整，需核对表头。
单位缺失风险	独立董事占比	2	独立董事 2 位非独立董事 1 位 独董担任主任委员	输出缺少单位或单位语境不完整，需核对表头。
比例误作数量风险	董事会人数	9 人	公司董事会由 9 名董事构成。其中，非独立董事 6 名，独立董事 3 名；女性董事 3 名，占比 33%。	证据含比例表达，需确认是否误作数量。
比例误作数量风险	客户投诉	100%	客户投诉处理率 100%	证据含比例表达，需确认是否误作数量。

定量样例中，温室气体排放总量可从表格证据中抽取 value 与 unit；定性样例中，绿色产品与服务需要保留语义完整的原文片段；机制性布尔样例中，碳排放管理措施必须有制度或组织安排证据。风险样例则展示了单位缺失、比例语境、金额单位、零事件和过短证据等复核重点。通过这些样例放入系统页面，评审者可直接按 report_id、indicator_id 和 block_id 回到具体证据。

7.7 系统展示与复核流程

系统总览页展示报告数、指标数、任务数、found/missing/error 运行状态、后处理修复数和风险样本数，真实页面见图 5-7。公司视角可查看单份报告的所有指标结果，指标视角可横向查看某一指标在 200 份报告中的披露与字段样例，分别见图 5-8 与图 5-9。证据核验页支持按维度、指标类型、状态、风险标签、报告和指标名称筛选，筛选结果表直接展示 evidence_quote、page_no 和 block_id，见图 5-10。高风险样本页按 risk_level 与 suspected_issue_type 组织复核，见图 5-11。新报告接入页展示单份 PDF 的处理入口和预期输出文件。该系统把结构化字段与证据字段放在同一界面中，避免结果展示脱离证据来源。

8. 模型评价

8.1 模型优点

本文方法的主要优点在于：一是将 PDF 解析为内容块，保留页码和块号，使结构化结果可以回溯；二是用 ESG-65 指标体系区分定量、定性和机制性指标，避免所有指标共用单一抽取模板；三是通过候选证据召回降低长文档噪声，使 qwen3 在局部证据内完成语义抽取；四是使用固定 JSON schema、后处理和质量诊断提高字段稳定性；五是通过 Streamlit 系统把结果查看、证据定位、风险样本和下载功能串联起来。

8.2 局限性

本文仍存在客观局限。关键词召回对同义表达和行业特定术语仍可能漏召；跨页表格、图片化文字和复杂合并单元格可能在解析阶段损失上下文；部分 ESG 指标的行业口径差异较大，同一字段在不同行业中的含义可能不同；自动质量诊断不能替代完整人工标注；当前模型不构建 ESG 评分模型，也不输出企业优劣排序；大语言模型输出仍需要 evidence_quote 与风险规则共同约束。

8.3 改进方向

后续可从六个方向改进：引入 embedding 召回以补充关键词漏召；增强跨页表格结构恢复；建立行业口径规则和单位标准化字典；构建覆盖多行业的人工真值集；对高风险指标设计专项规则；进一步优化系统界面的证据跳转、批注和复核记录功能。

9. 结论

本文围绕 ESG 长 PDF 报告中的定量与定性指标识别，建立了证据约束型结构化抽取模型。模型以 200 份报告和 ESG-65 指标体系为输入，将任务拆解为 13000 个 report-indicator 结构化抽取问题，通过 MinerU 解析、内容块建模、候选证据召回、qwen3 约束抽取、后处理和质量诊断生成可追溯结果。实验结果显示，正式批次形成 7777 条 found 与 5223 条 missing 运行结果，并保留完整 page_no 与 block_id 字段；质量诊断进一步识别 164 个具体风险样本，为人工复核提供优先级。最后，Streamlit 系统将公司视角、指标视角、证据核验、风险样本和新报告接入整合为闭环，使结构化结果不仅可输出为 CSV/JSON，也可被逐条核验。

10. 参考文献

- [1] Global Reporting Initiative. GRI Standards[EB/OL]. 2021. <https://www.globalreporting.org/standards/>.
- [2] International Sustainability Standards Board. IFRS S1 and IFRS S2 Sustainability Disclosure Standards[EB/OL]. 2023. <https://www.ifrs.org/issued-standards/ifrs-sustainability-standards-navigator/>.
- [3] Task Force on Climate-related Financial Disclosures. Recommendations of the Task Force on Climate-related Financial Disclosures[EB/OL]. 2017. <https://www.fsb-tcfd.org/recommendations/>.
- [4] ZHONG X, TANG J, YEPES A J. PubLayNet: Largest Dataset Ever for Document Layout Analysis[C]//International Conference on Document Analysis and Recognition. 2019.
- [5] SMOCK B, PESALA R, ABRAHAM R. PubTables-1M: Towards Comprehensive Table Extraction From Unstructured Documents[C]//CVPR Workshop. 2022.
- [6] CUI Y, et al. MinerU: An Open-Source Solution for Precise Document Content Extraction[J]. arXiv preprint, 2025.
- [7] BAI J, et al. Qwen Technical Report[J]. arXiv preprint arXiv:2309.16609, 2023.
- [8] Ollama. Ollama Documentation[EB/OL]. 2026. <https://ollama.com/>.
- [9] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[J]. Advances in Neural Information Processing Systems, 2020.
- [10] Streamlit. Streamlit Documentation[EB/OL]. 2026. <https://docs.streamlit.io/>.

附录 A 关键模型代码

1.1 内容块构造与候选召回

```
for report in reports:
    blocks = parse_pdf_to_blocks(report)
    for indicator in indicators:
        candidates = []
        for block in blocks:
            score = keyword_score(block, indicator)
            score += unit_score(block, indicator)
            score += block_type_score(block)
            score += position_score(block)
            if score > 0:
                candidates.append((score, block))
        evidence = top_k(candidates, k)
        if evidence is empty:
            emit_missing(report, indicator)
        else:
            constrained_extract(report, indicator, evidence)
```

1.2 证据约束抽取与后处理

```
def constrained_extract(report, indicator, evidence):
    prompt = build_prompt(indicator, evidence)
    raw = call_llm(prompt)
    record = parse_json_schema(raw)

    if record.status == "found":
        require_quote_from_evidence(record.evidence_quote, evidence)
        require_trace_fields(record.page_no, record.block_id)
        if indicator.type == "quantitative":
            require_value_and_unit(
                record.value, record.unit
            )
        if indicator.type == "boolean":
            reject_title_only_evidence(
                record.evidence_quote
            )

    record = normalize_zero_event(record)
    record = repair_common_unit(record)
    record.risk_tag = diagnose_risk(record, indicator, evidence)
    return record
```